Classification non supervisée (Clustering)

(Dis)similarités, distances et inerties

Cathy Maugis-Rabusseau

4modIA / INSA Toulouse & ENSEEIHT

2026-2027

Objectif

- Données : On observe n individus décrits par p variables

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \text{ avec } x_i = (x_{i1}, \ldots, x_{ip}) \in \mathcal{X}$$

- Objectif de la classification non supervisée :

  trouver une organisation en classes homogènes de n individus telle que

  - 2 individus d'une même classe **se ressemblent** plus que deux individus de classes différentes
  - les classes soient bien **séparées**

$\Longrightarrow$ besoin pour certains types de méthodes d'une notion de (dis)similarité entre individus et d'une mesure de séparabilité des classes.

Chapitre 1 - (Dis)similarités, distances et inerties

1. (Dis)similarités et distances
   - Définitions
   - Pour des variables quantitatives
   - Pour des variables qualitatives
   - Pour des variables mixtes
2. Inerties

Chapitre 1 - (Dis)similarités, distances et inerties

1. (Dis)similarités et distances
   - Définitions
   - Pour des variables quantitatives
   - Pour des variables qualitatives
   - Pour des variables mixtes

(Dis)similarité entre individus

Dissimilarité

Une **dissimilarité** est une fonction $d : \mathcal{X} \times \mathcal{X} \to \mathbb{R}^+$ telle que

- $\forall (x_i, x_\ell) \in \mathcal{X} \times \mathcal{X},\ d(x_i, x_\ell) = d(x_\ell, x_i)$ (symétrie)
- $d(x_i, x_\ell) = 0 \Leftrightarrow x_i = x_\ell$

Similarité

Une **similarité** (normée) est une fonction $s : \mathcal{X} \times \mathcal{X} \to [0, 1]$ telle que

- $\forall (x_i, x_\ell) \in \mathcal{X} \times \mathcal{X},\ s(x_i, x_\ell) = s(x_\ell, x_i)$ (symétrie)
- $s(x_i, x_\ell) = 1 \Leftrightarrow x_i = x_\ell$

Distances entre individus

Distance

Une **distance** est une dissimilarité d satisfaisant en plus l'inégalité triangulaire

$$\forall (x_i, x_\ell, x_m) \in \mathcal{X}^3,\ d(x_i, x_m) \leq d(x_i, x_\ell) + d(x_\ell, x_m)$$

La distance est dite **euclidienne** s'il existe un produit scalaire sur l'espace des variables, de norme associée $\|.\|$, tel que

$$d(x_i, x_\ell) = \|x_i - x_\ell\|,$$

c'est-à-dire

$$d^2(x_i, x_\ell) = (x_i - x_\ell)' M (x_i - x_\ell)$$

avec M symétrique définie positive.

Distance ultramétrique

Distance ultramétrique

Une distance d est dite **ultramétrique** si elle satisfait l'inégalité ultra-triangulaire

$$\forall (x_i, x_\ell, x_m) \in \mathcal{X}^3,\ d(x_i, x_m) \leq \max\left[d(x_i, x_\ell), d(x_\ell, x_m)\right]$$

Chapitre 1 - (Dis)similarités, distances et inerties

1. (Dis)similarités et distances
   - Définitions
   - Pour des variables quantitatives
   - Pour des variables qualitatives
   - Pour des variables mixtes

Norme L_q et norme infinie

- $x_i \in \mathcal{X} = \mathbb{R}^p$ pour tout $i = 1, \dots, n$
- Distance de Minkowski (norme L_q)

$$d(x_i, x_\ell) = \left(\sum_{j=1}^{p} |x_{ij} - x_{\ell j}|^q \right)^{\frac{1}{q}}$$

- Cas particuliers :
  - Distance euclidienne usuelle $(q = 2)$

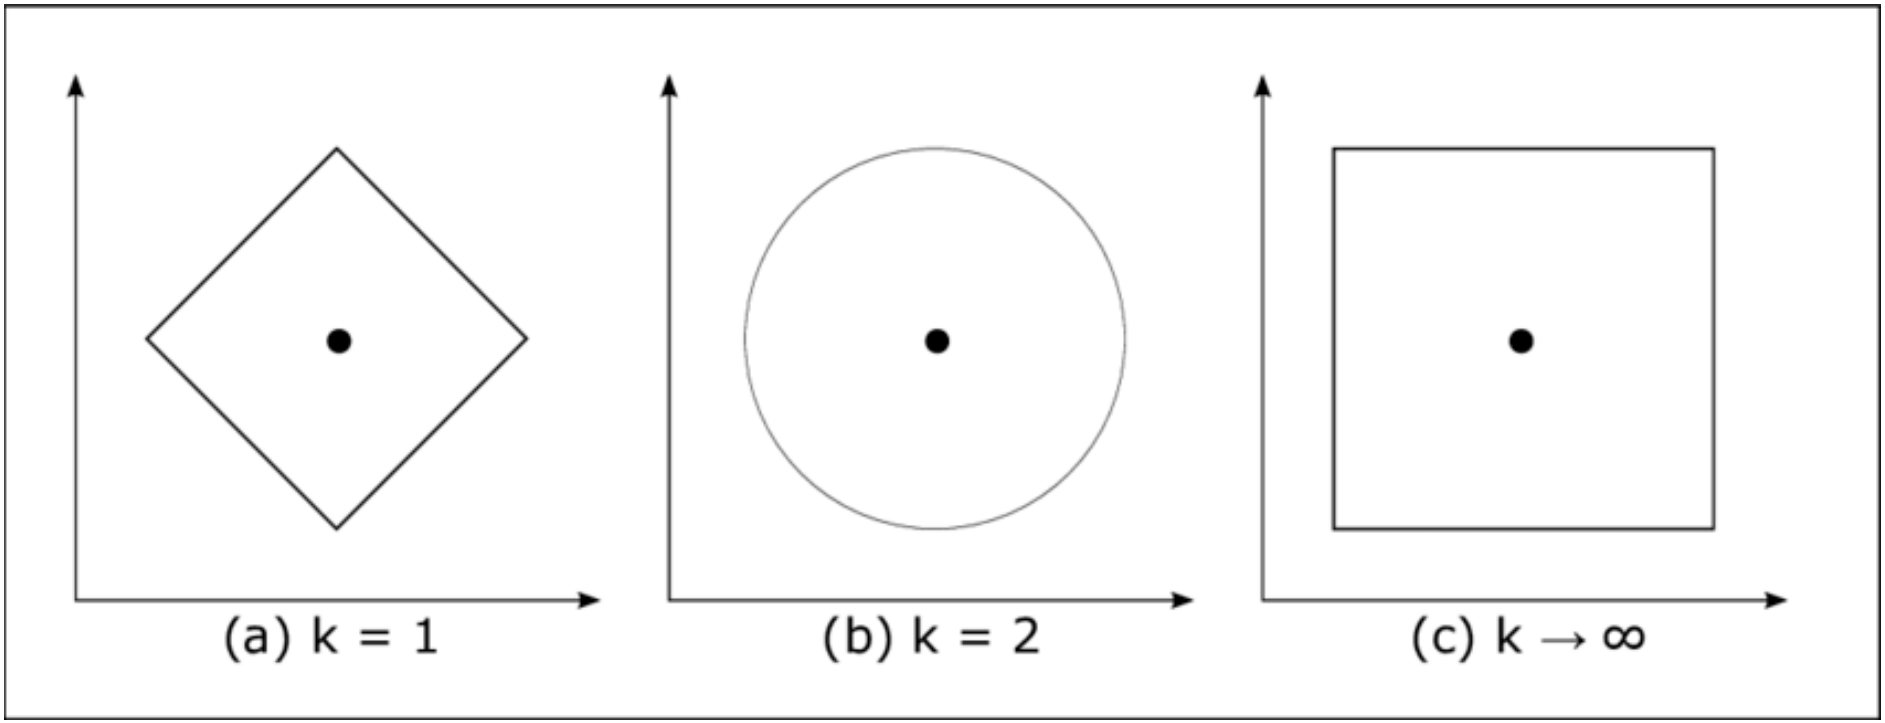
$$d(x_i, x_\ell) = \|x_i - x_\ell\|_2 = \sqrt{\sum_{j=1}^{p} (x_{ij} - x_{\ell j})^2}$$

  - Distance de Manhattan $(q = 1)$ $d(x_i, x_\ell) = \|x_i - x_\ell\|_1 = \sum_{j=1}^{p} |x_{ij} - x_{\ell j}|$

- Norme infinie $d(x_i, x_\ell) = \max_{j=1,\dots,p} |x_{ij} - x_{\ell j}|$

$\Longrightarrow$ invariantes par translation mais sensibles à l'échelle des variables.

Norme L_q et norme infinie



Définitions

- Moyennes par variable

$$\forall j \in \{1, \dots, p\},\ m_j = \frac{1}{n} \sum_{i=1}^{n} x_{ij}$$

- Déviation absolue moyenne

$$\forall j \in \{1, \dots, p\},\ s_j = \frac{1}{n} \sum_{i=1}^{n} |x_{ij} - m_j|$$

- z-score robuste (Kaufman and Rousseeuw 2009) :

$$\forall j \in \{1, \dots, p\}, \forall i \in \{1, \dots, n\}\ z_{ij} = \frac{x_{ij} - m_j}{s_j}$$

(le z-score usuel divise par l'écart-type σ_j)

- Covariances

$$\forall (j, q) \in \{1, \dots, p\}^2,\ \Sigma_{jq} = \frac{1}{n} \sum_{i=1}^{n} (x_{ij} - m_j)(x_{iq} - m_q)$$

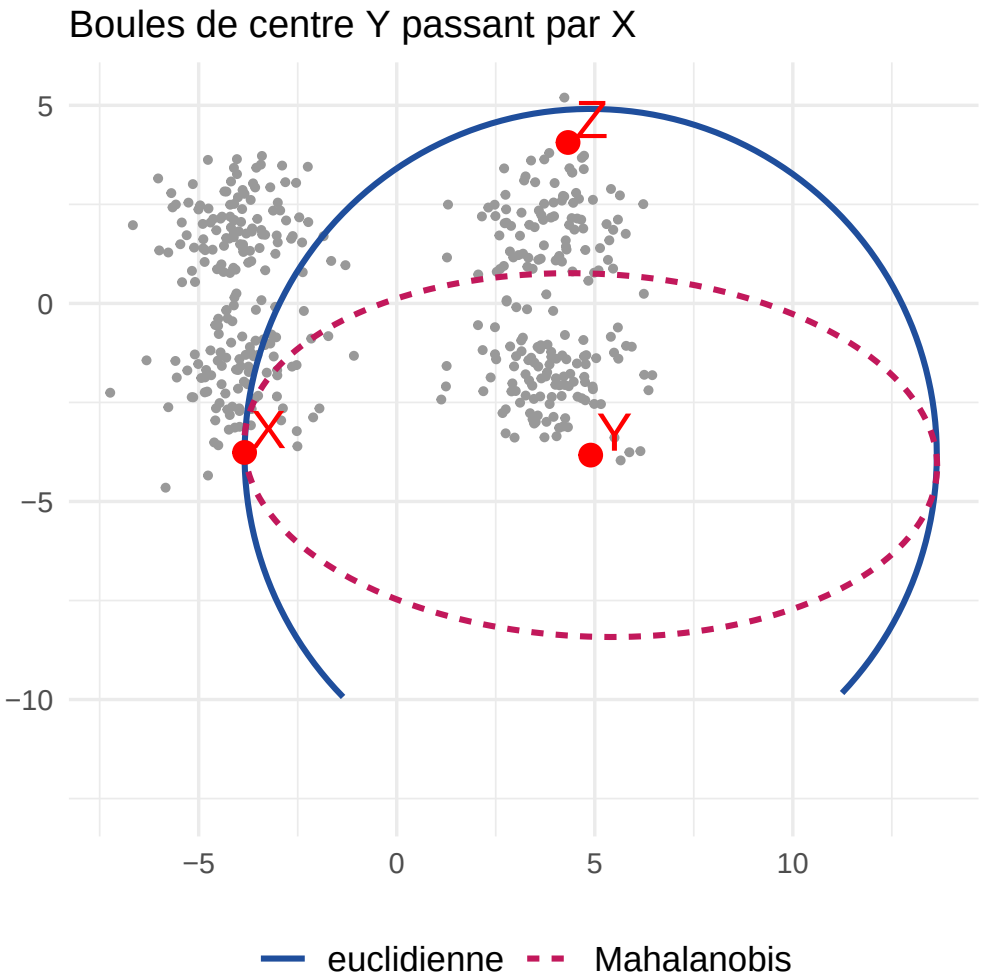
Formes quadratiques

Distances définies comme des formes quadratiques

$$d^2(x_i, x_\ell) = (x_i - x_\ell)' M (x_i - x_\ell) = \|x_i - x_\ell\|^2_{2,M}$$

- Norme euclidienne usuelle : $M = I_p$
- $M = \text{diag}\left(\frac{1}{\sigma_1^2}, \dots, \frac{1}{\sigma_p^2}\right)$ où $\sigma_j^2 = \Sigma_{jj}$
- $M = \text{diag}\left(\frac{1}{s_1^2}, \dots, \frac{1}{s_p^2}\right)$
- Distance de Mahalanobis : $M = \Sigma^{-1}$

Exemples



Paire	$\|.\|_2$	$\|.\|_1$	$\|.\|_{2,\Sigma^{-1}}$
(X,Y)	8.74	8.80	**2.14**
(X,Z)	11.31	15.99	4.28
(Y,Z)	**7.91**	**8.46**	3.68

$$\Sigma = \begin{pmatrix} 16.66 & -0.53 \\ -0.53 & 4.59 \end{pmatrix}$$

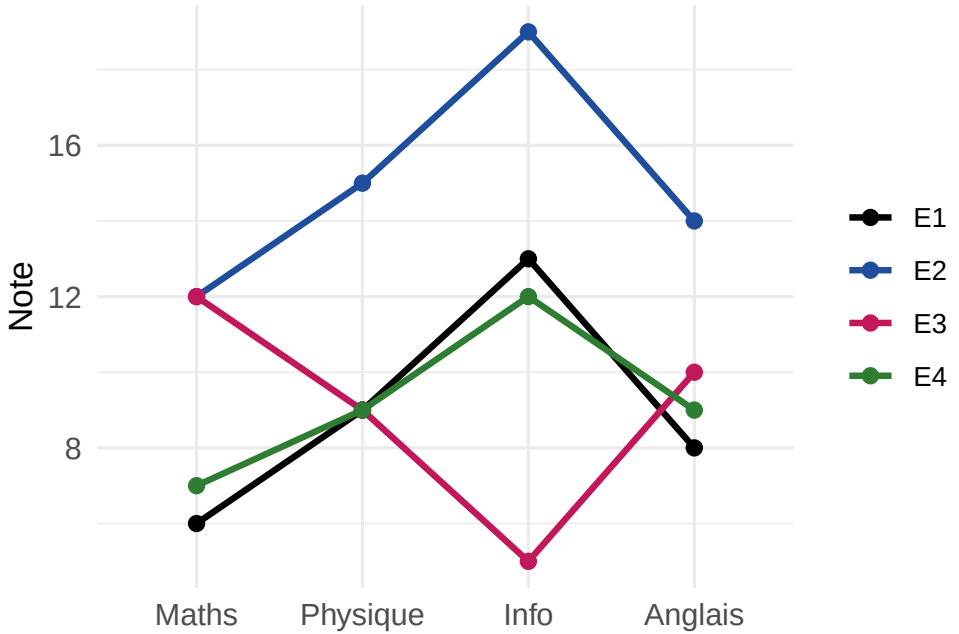
- $\|.\|_2$, $\|.\|_1$: Z est le plus proche de Y (Z dans le cercle)
- $\|.\|_{2,\Sigma^{-1}}$ (Mahalanobis) :

X est le plus proche de Y (Z hors de l'ellipse : la variance est plus forte selon l'axe horizontal)

$\Rightarrow$ le choix de la distance change le voisinage

Basées sur la corrélation

- Coefficient de corrélation $\rho(x_i, x_\ell)$ calculé sur les p valeurs des deux individus : compare la **forme des profils**, pas leur niveau
- Dissimilarités :
  - $d(x_i, x_\ell) = 1 - \rho(x_i, x_\ell)$
  - $d(x_i, x_\ell) = 1 - |\rho(x_i, x_\ell)|$
  - $d(x_i, x_\ell) = 1 - \rho(x_i, x_\ell)^2$



	E_2	E_3	E_4
$1 - \rho(E_1, .)$	0.00	2.00	0.01
$1 - \lvert\rho(E_1, .)\rvert$	0.00	0.00	0.01
$1 - \rho(E_1, .)^2$	0.00	0.00	0.02
$\lVert E_1 - . \rVert_2$	12.00	10.20	1.73

- E_2 : loin de E_1 pour $\|.\|_2$, identique à E_1 pour la corrélation
- E_3 : $1 - |\rho|$ et $1 - \rho^2$ ignorent aussi le **sens** du profil

Chapitre 1 - (Dis)similarités, distances et inerties

1. (Dis)similarités et distances
   - Définitions
   - Pour des variables quantitatives
   - Pour des variables qualitatives
   - Pour des variables mixtes

Pour des variables binaires

- Table de contingence entre 2 individus x_i et $x_\ell \in \{0,1\}^p$:

	1	0
1	m_{11}	m_{10}
0	m_{01}	m_{00}

- Variable binaire **symétrique**
  = pas d'influence sur le choix du codage $0-1$

Appariement simple $\quad s(x_i,x_\ell) = \frac{m_{11}+m_{00}}{m_{11}+m_{00}+m_{10}+m_{01}}$

Rogers et Tanimoto $\quad s(x_i,x_\ell) = \frac{m_{11}+m_{00}}{m_{11}+m_{00}+2(m_{10}+m_{01})}$

Sokal et Sneath $\quad s(x_i,x_\ell) = \frac{2\ (m_{11}+m_{00})}{2(m_{11}+m_{00})+m_{10}+m_{01}}$

- Variable binaire **asymétrique**
  = les valeurs 0-1 n'ont pas la même importance

Jaccard $\quad s(x_i,x_\ell) = \frac{m_{11}}{m_{11}+m_{10}+m_{01}}$

Dice $\quad s(x_i,x_\ell) = \frac{2m_{11}}{2\ m_{11}+m_{10}+m_{01}}$

Exemple

- Paniers de 4 clients sur $p = 8$ produits ($1 =$ acheté) : variables **asymétriques**

	Pain	Lait	Café	Thé	Vin	Bière	Fromage	Chocolat
Alice	**1**	**1**	**1**	0	0	0	0	0
Bruno	**1**	**1**	**1**	0	0	0	**1**	0
Chloé	0	0	0	**1**	0	0	0	0
David	0	0	0	0	0	0	0	**1**

Appariement simple

	A	B	C	D
Alice	–	0.88	0.50	0.50
Bruno	0.88	–	0.37	0.37
Chloé	0.50	0.37	–	0.75
David	0.50	0.37	0.75	–

Jaccard

	A	B	C	D
Alice	–	0.75	0.00	0.00
Bruno	0.75	–	0.00	0.00
Chloé	0.00	0.00	–	0.00
David	0.00	0.00	0.00	–

- Appariement simple : $s(\text{Chloé}, \text{David}) = 0.75$

(**aucun** achat commun mais $m_{00} = 6$ absences communes)

- Jaccard : $s(\text{Chloé}, \text{David}) = 0$ (ignore les absences communes m_{00})

Pour des variables nominales

- Variables ayant plus de 2 modalités
  - Ex1 : couleur des yeux $\{$bleu, marron, vert$\}$
  - Ex2 : statut marital : $\{$marié, célibataire, pacsé, divorcé, veuf$\}$
- Coefficient d'appariement simple :

$$s(x_i, x_\ell) = \frac{u}{p}$$

où $u =$ nombre de variables où x_i et x_ℓ ont la même modalité

Pour des variables nominales

- Transformer la variable nominale en variables binaires (une par modalité)

Le tableau disjoint complet $\mathbf{Z}$ associé à $\mathbf{X}$ de taille $n \times \tilde{p}$:

$$\mathbf{X} = \begin{pmatrix} 2 & 2 & 1 \\ 1 & 3 & 4 \\ 2 & 1 & 1 \\ \vdots & \vdots & \vdots \end{pmatrix} \Rightarrow \mathbf{Z} = \begin{pmatrix} 0 & 1 & 0 & 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 & 0 & 1 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \end{pmatrix}$$

$+$ distance pour variables binaires

- Distance du χ^2 entre individus :

$$d^2(x_i, x_\ell) = \frac{1}{p} \sum_{j=1}^{\tilde{p}} \frac{(z_{ij} - z_{\ell j})^2}{z_{\cdot j}} \text{ avec } z_{\cdot j} = \frac{1}{n} \sum_{i=1}^{n} z_{ij}$$

- Distance pour données quantitatives sur les coordonnées de l'ACM

Exemple des races de chien

	TAI	POI	VEL	INT	AFF	AGR
beauceron	3	2	3	2	2	2
ber_allem	3	2	3	3	2	2
caniche	1	1	2	3	2	1
teckel	1	1	1	2	2	1
epagn_bre	2	2	2	3	2	1
labrador	2	2	2	2	2	1

- Appariement simple

	beauceron	ber_allem	caniche	teckel	epagn_bre	labrador
beauceron	1.00	0.83	0.17	0.33	0.33	0.50
ber_allem	0.83	1.00	0.33	0.17	0.50	0.33
caniche	0.17	0.33	1.00	0.67	0.67	0.50
teckel	0.33	0.17	0.67	1.00	0.33	0.50
epagn_bre	0.33	0.50	0.67	0.33	1.00	0.83
labrador	0.50	0.33	0.50	0.50	0.83	1.00

Exemple des races de chien

- Distance du χ^2 sur $\mathbf{Z}$:

	beauceron	ber_allem	caniche	teckel	epagn_bre	labrador
beauceron	0.00	1.05	2.13	1.83	2.02	1.73
ber_allem	1.05	0.00	1.86	2.11	1.73	2.02
caniche	2.13	1.86	0.00	1.45	1.51	1.84
teckel	1.83	2.11	1.45	0.00	2.10	1.82
epagn_bre	2.02	1.73	1.51	2.10	0.00	1.05
labrador	1.73	2.02	1.84	1.82	1.05	0.00

- Distance euclidienne sur les coefficients de l'ACM

	beauceron	ber_allem	caniche	teckel	epagn_bre	labrador
beauceron	0.00	0.98	1.70	1.70	1.38	1.25
ber_allem	0.98	0.00	1.46	2.04	1.25	1.77
caniche	1.70	1.46	0.00	1.21	1.23	1.70
teckel	1.70	2.04	1.21	0.00	1.90	1.72
epagn_bre	1.38	1.25	1.23	1.90	0.00	0.98
labrador	1.25	1.77	1.70	1.72	0.98	0.00

- Rem : l'ACM ne garde ici que 5 axes (`ncp=5` par défaut). Avec tous les axes, la distance euclidienne sur les coordonnées de l'ACM est égale à la distance du χ^2.

Chapitre 1 - (Dis)similarités, distances et inerties

1. (Dis)similarités et distances
   - Définitions
   - Pour des variables quantitatives
   - Pour des variables qualitatives
   - Pour des variables mixtes

Cas des variables mixtes

- 1ère stratégie : tout transformer en variables de même nature
- 2ème stratégie : métrique de Gower

$$d(x_i, x_\ell) = \sum_{j=1}^{p} \delta_{i\ell}^{(j)} d_{i\ell}^{(j)} / \sum_{j=1}^{p} \delta_{i\ell}^{(j)}$$

avec

$$\delta_{i\ell}^{(j)} = \begin{cases} 0 & \text{si} \begin{cases} x_{ij} \text{ ou } x_{\ell j} \text{ est manquante} \\ x_{ij} = x_{\ell j} = 0 \text{ et } j \text{ variable binaire asymétrique} \end{cases} \\ 1 & \text{sinon.} \end{cases}$$

et

$$d_{i\ell}^{(j)} = \begin{cases} \mathbb{1}_{x_{ij} \neq x_{\ell j}} & \text{si } j \text{ variable binaire ou nominale} \\ \dfrac{|x_{ij} - x_{\ell j}|}{\max\limits_{1 \leq h \leq n} x_{hj} - \min\limits_{1 \leq h \leq n} x_{hj}} & \text{si } j \text{ est quantitative} \end{cases}$$

Exemple des données de maladie du coeur

```
library(VarSelLCM)
data(heart)

library(cluster)
DisGower<-daisy(heart,"gower")
round(as.matrix(DisGower)[1:5,1:5],2)
```

```
     1    2    3    4    5
1 0.00 0.47 0.44 0.41 0.49
2 0.47 0.00 0.47 0.48 0.47
3 0.44 0.47 0.00 0.42 0.50
4 0.41 0.48 0.42 0.00 0.42
5 0.49 0.47 0.50 0.42 0.00
```

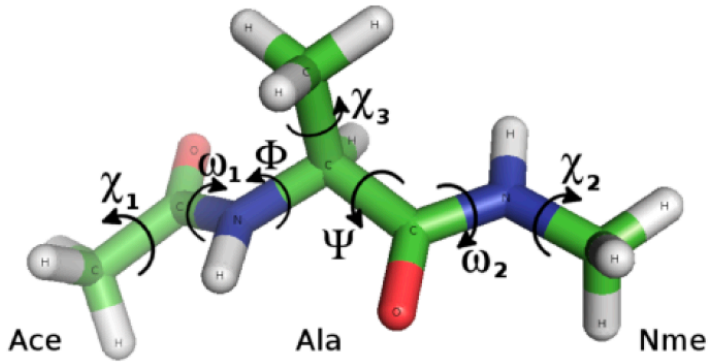
Et aussi ...

- Données compositionnelles (ex : en microbiome)
  - $x_i = (x_{i1}, \dots, x_{ip}) \in [0,1]^p,\ \sum_{j=1}^{p} x_{ij} = 1$
  - Distance d'Aitchison

$$d(x_i, x_\ell) = \|\mathrm{CLR}(x_i) - \mathrm{CLR}(x_\ell)\|_2$$

avec $\mathrm{CLR}(x_i) = (\ln(\frac{x_{ij}}{g(x_i)}))_j$ et $g(.)$ moyenne géométrique

- Données angulaires (ex : conformations de molécule)
  - $x_i = (x_{i1}, \dots, x_{ip}) \in]-\pi, \pi]^p$
  - $d(x_i, x_\ell) = \sum_{j=1}^{p} [\pi - ||x_{ij} - x_{\ell j}| - \pi|]$
  - $d(x_i, x_\ell) = \sum_{j=1}^{p} 2(1 - \cos(x_{ij} - x_{\ell j}))$
  - ...



Quelques commandes

- Avec R 
  - `dist()` : method= “euclidean”, “manhattan”, “minkowski”, “maximum”, “canberra”, “binary”
  - `daisy()` [library(cluster)] : metric= “euclidean”, “manhattan”, “gower”
  - Dans `library(ade4)` : `dist.binary()`, `dist.quant()`, `dist.ktab()`
- Avec Python 
  - `dist.euclidean` [Numpy]
  - `scipy.spatial.distance` [SciPy]

Conclusion

- Bien adapter le choix de la distance (dissimilarité) à
  - la nature des données étudiées
  - la définition de ressemblance entre individus dans le contexte
  - selon la méthode de clustering choisie
- Attention au comportement de la distance en grande dimension (beaucoup de variables)

Chapitre 1 - (Dis)similarités, distances et inerties

1 (Dis)similarités et distances

2 Inerties

Inerties intra- / inter- classes

Soit d une distance euclidienne entre individus.
Soit $\mathcal{P} = \{\mathcal{C}_1, \dots, \mathcal{C}_K\}$ une partition des individus en K classes.

- **Inertie totale** : $I_T = \sum_{i=1}^{n} d(x_i, c)^2$

  où $c = \frac{1}{n} \sum_{i=1}^{n} x_i$ est le centre de gravité du nuage de points

- **Inertie interclasse** : $I_{inter} = \sum_{k=1}^{K} |\mathcal{C}_k| \times d(m_k, c)^2$

  où $m_k = \frac{1}{|\mathcal{C}_k|} \sum_{i \in \mathcal{C}_k} x_i$ est le centre de gravité de la classe $\mathcal{C}_k$

  $\Rightarrow$ variance des centres des classes

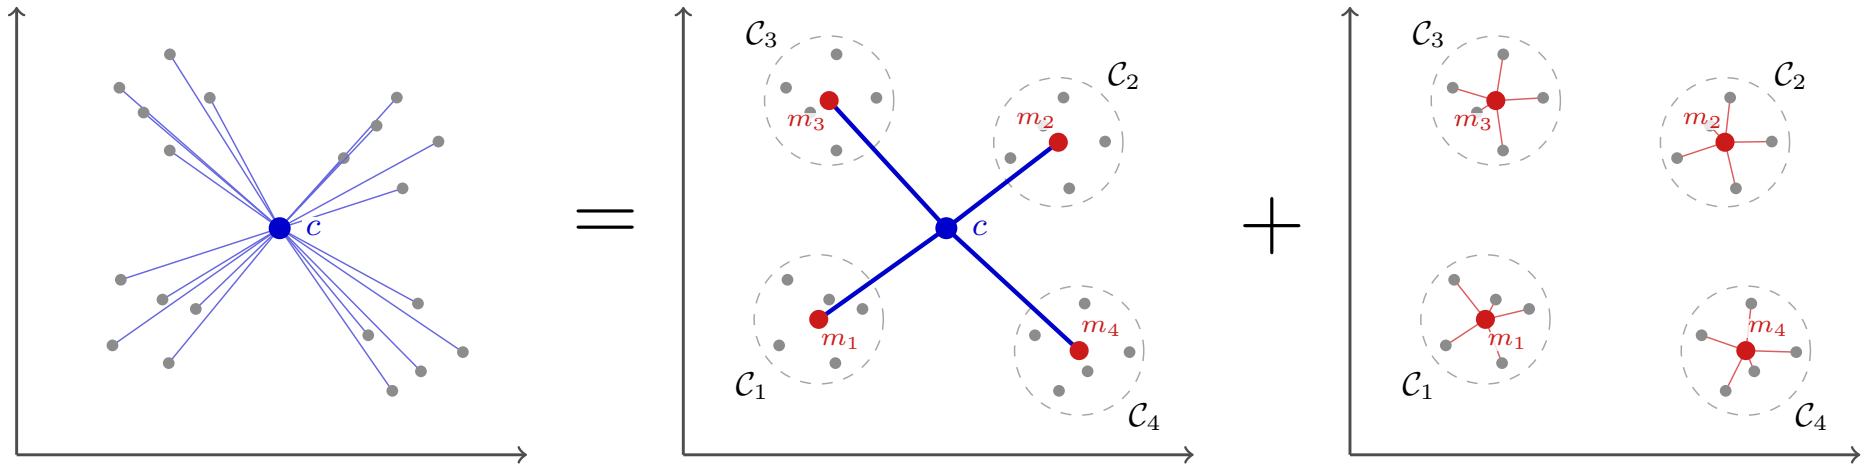
- **Inertie intra-classe** : $I_{intra} = \sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} d(x_i, m_k)^2$

  $\Rightarrow$ variance des points d'une même classe

Propriété de Huygens

Propriété de Huygens

$$I_T = I_{inter} + I_{intra}$$



$$I_T = \sum_{i=1}^{n} d(x_i, c)^2$$

$$I_{inter} = \sum_{k=1}^{K} |\mathcal{C}_k| \, d(m_k, c)^2$$

$$I_{intra} = \sum_{k=1}^{K} \sum_{i \in \mathcal{C}_k} d(x_i, m_k)^2$$

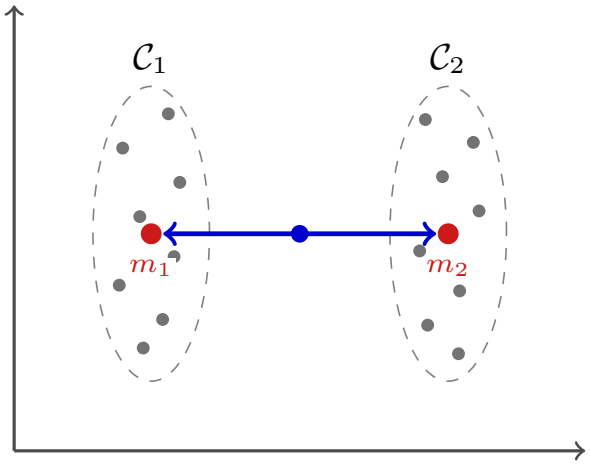
d'après Bisson (2001)

Objectif

on veut minimiser l'inertie intra-classe

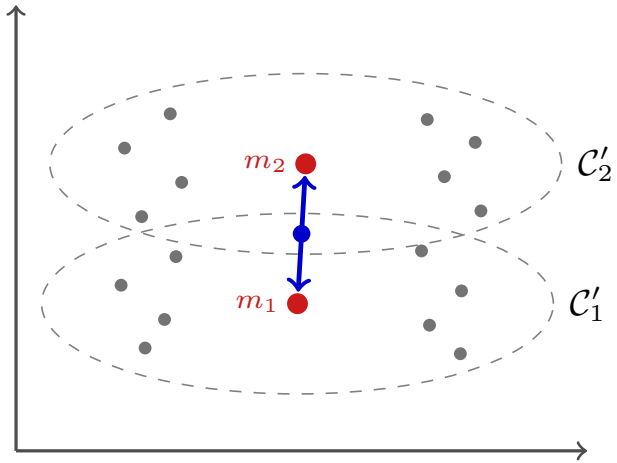
$\Longleftrightarrow$

maximiser l'inertie inter-classe



Forte inertie inter-classe
Faible inertie intra-classe

$I_{inter} = 27.0,\ I_{intra} = 8.2\ \ (I_T = 35.2)$



Faible inertie inter-classe
Forte inertie intra-classe

$I_{inter} = 6.0,\ I_{intra} = 29.2\ \ (I_T = 35.2)$

d'après Bisson (2001)

References I

Aitchison, John. 1982. "The Statistical Analysis of Compositional Data." *Journal of the Royal Statistical Society: Series B (Methodological)* 44 (2): 139–60.

Bisson, G. 2001. "Catégorisation Et Textes."

Gower, John C. 1971. "A General Coefficient of Similarity and Some of Its Properties." *Biometrics*, 857–71.

Kaufman, Leonard, and Peter J Rousseeuw. 2009. *Finding Groups in Data: An Introduction to Cluster Analysis*. John Wiley & Sons.

Thioulouse, Jean, and Stéphane Dray. 2007. "Interactive Multivariate Data Analysis in r with the Ade4 and ade4TkGUI Packages." *Journal of Statistical Software* 22: 1–14.