Classification non supervisée (Clustering)

Introduction

Cathy Maugis-Rabusseau

4modIA / INSA Toulouse & ENSEEIHT

2026-2027

Plan du cours

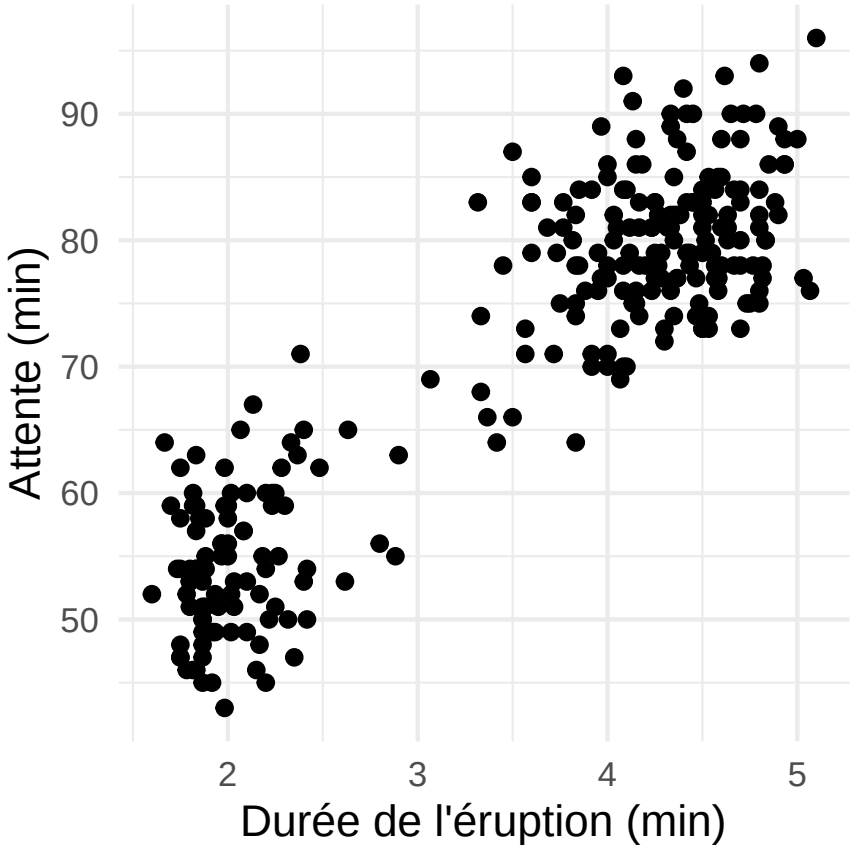
- Chapitre 0 : Introduction
- Chapitre 1 : (Dis)similarités, distances et inerties
- Chapitre 2 : Méthodes de type K-means et DBSCAN
- Chapitre 3 : Classification non supervisée hiérarchique
- Chapitre 4 : Classification par modèles de mélanges finis

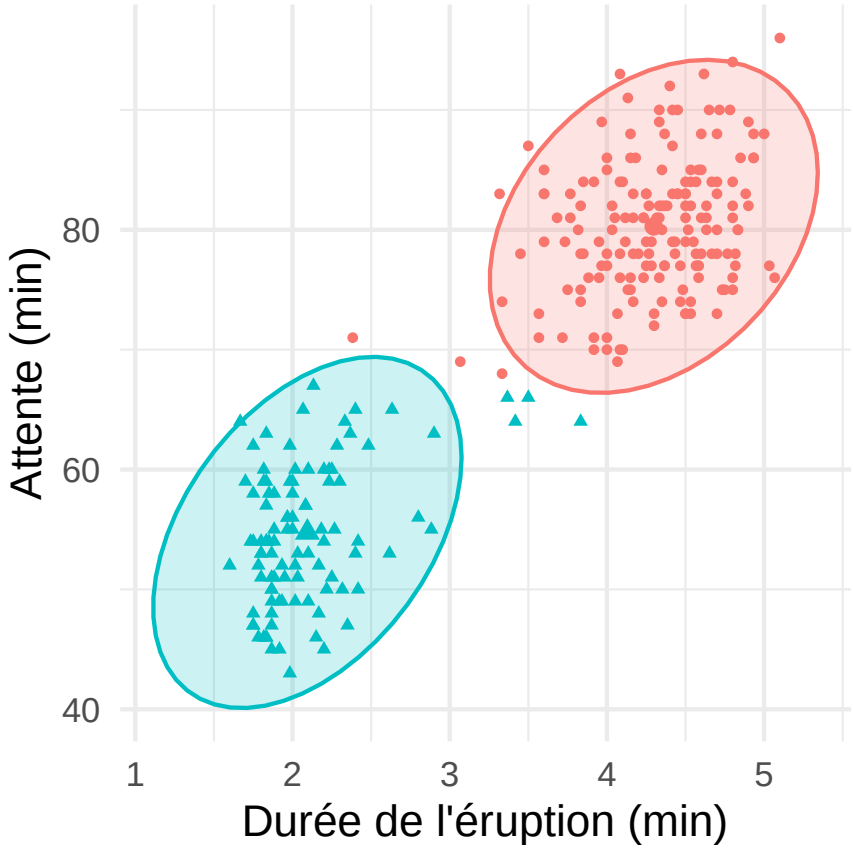
Chapitre 0 - Introduction

1. Exemples introductifs
2. Principe du clustering
3. Outils pour comparer des clusterings
4. Suite du cours
5. References

Old Faithful Geyser Data

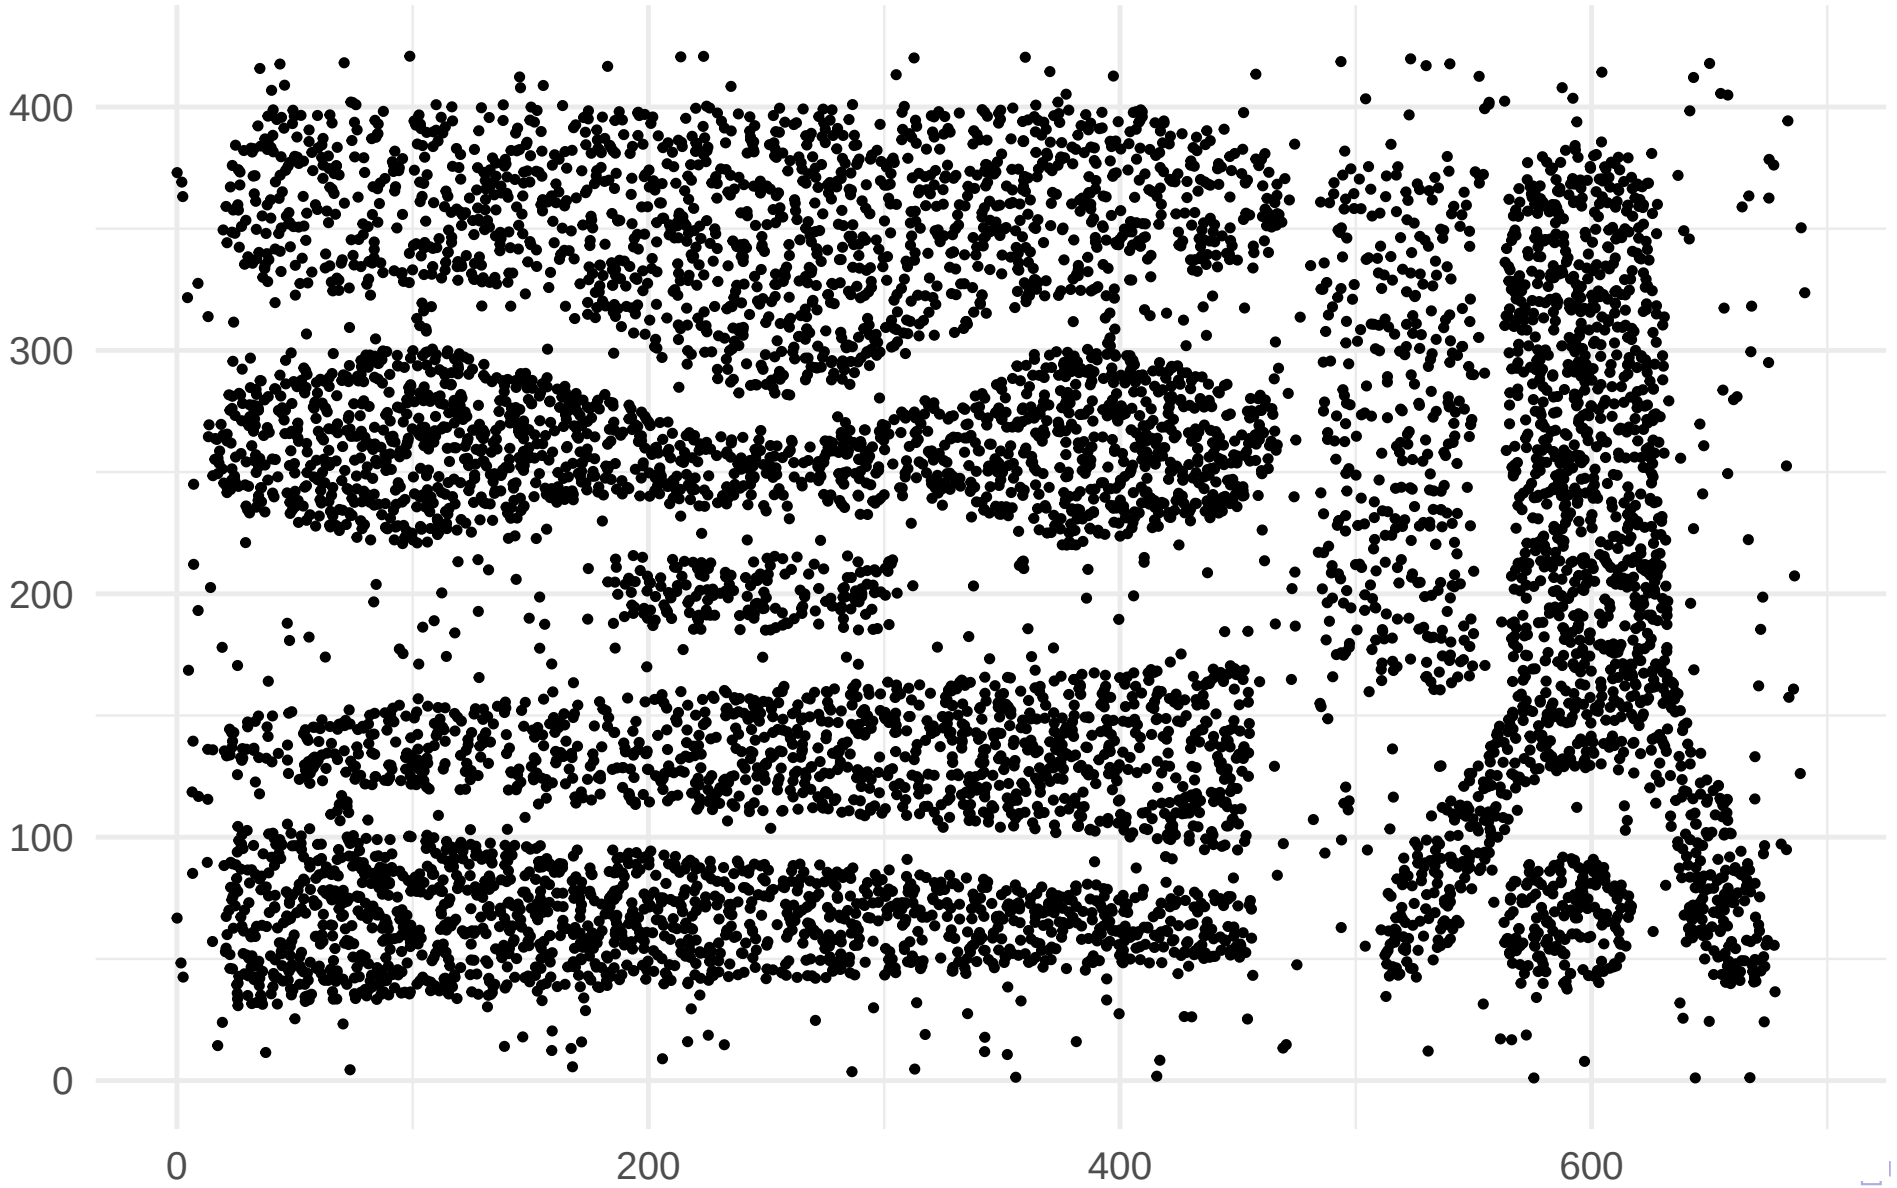
Azzalini and Bowman (1990)





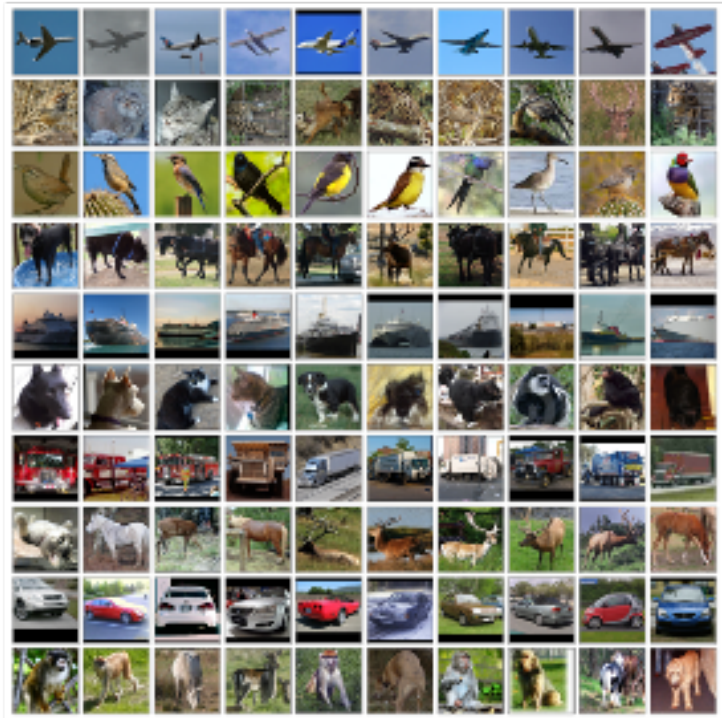
Exemple de clustering de formes

George and Eui-Hong (1999)

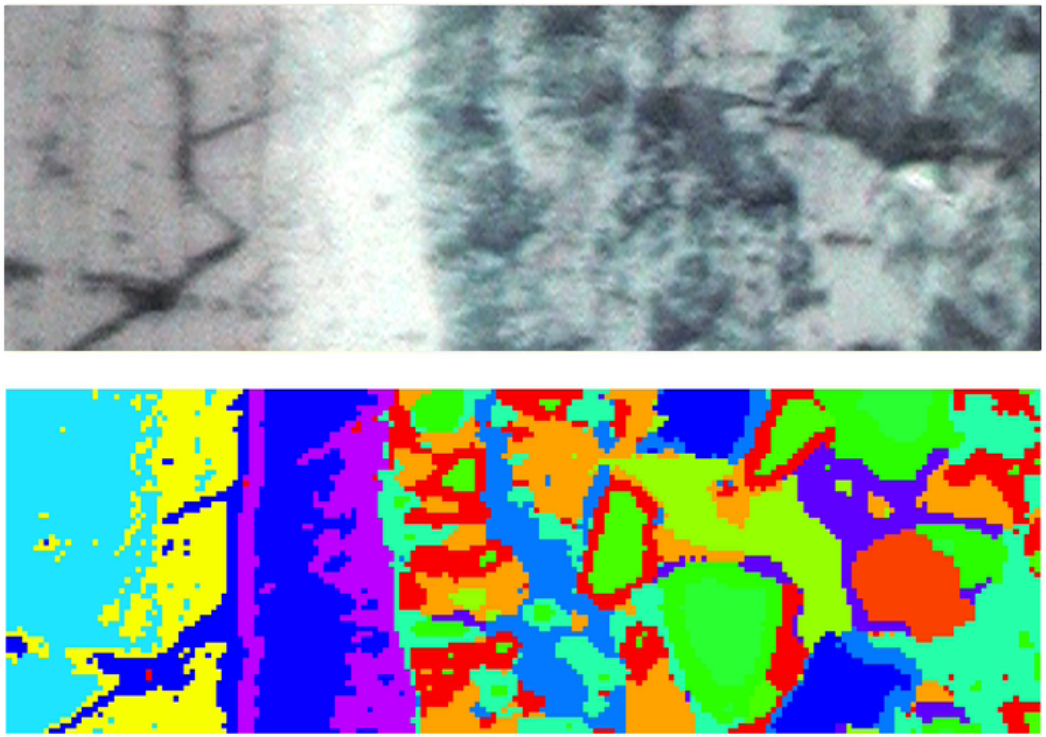


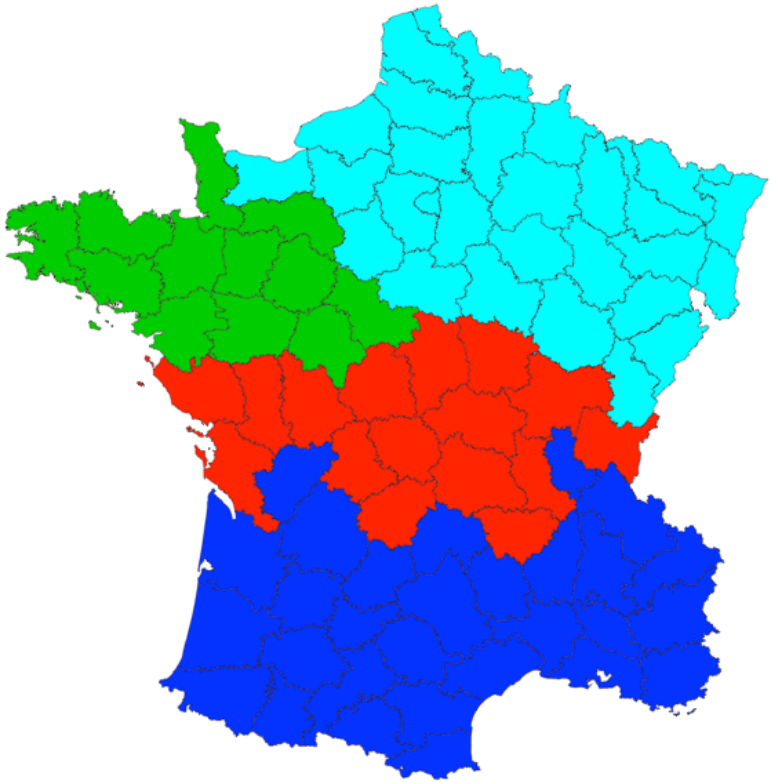
Exemple de clustering d'images





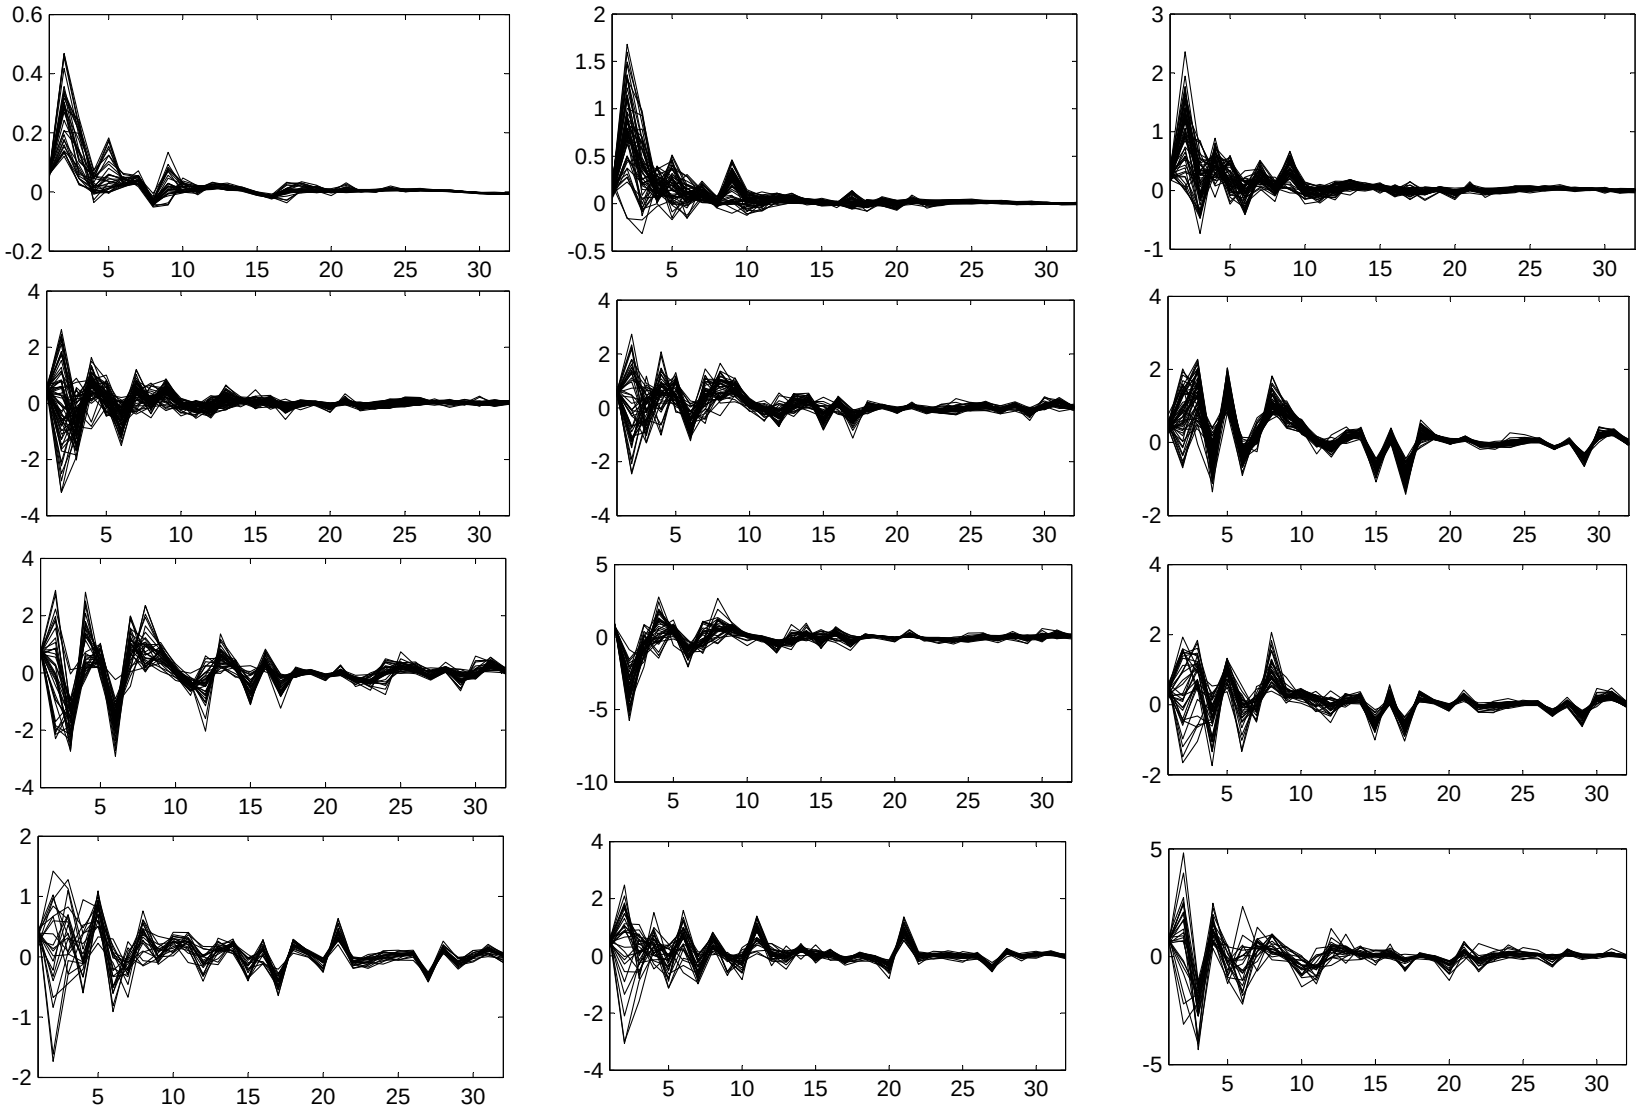
Exemple avec contraintes spatiales





Le Pennec and Cohen (2011)

Exemple de clustering de courbes



Chapitre 0 - Introduction

1. Exemples introductifs
2. Principe du clustering
3. Outils pour comparer des clusterings
4. Suite du cours
5. References

Les données

- On observe **n** individus décrits par **p** variables

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \text{ avec } x_i = (x_{i1}, \ldots, x_{ip}) \in \mathcal{X}$$

- L'ensemble $\mathcal{X}$ peut-être de nature très différente :
  $\mathcal{X} = \mathbb{R}^p$, $\{0,1\}^p$, $]-\pi, \pi]^p$, $\mathbb{R}^q \times \{0,1\}^{p-q}$, ...
- On peut partir du
  - Tableau initial des mesures
  - Tableau des mesures transformées
  - Tableau des coordonnées après une réduction de dimension

Objectif du clustering

- Soit $\mathbf{X}$ la matrice de données décrivant n individus
- **Classification** : organisation d'un ensemble d'individus hétérogènes en un ensemble de classes homogènes
- **Non supervisée** : on ne dispose d'aucune partition a priori des n individus et on ne connait pas le nombre de classes K.
- **Objectif** : Déterminer K classes $\mathcal{P}_K = \{\mathcal{C}_1, \ldots, \mathcal{C}_K\}$ des n individus à partir de $\mathbf{X}$ telles qu'une classe est une collection d'individus **similaires** entre eux et **dissimilaires** aux individus des autres classes (classes bien séparées).

Vocabulaire

Attention à la confusion de terminologie entre le français et l'anglais!

- **Classification non supervisée** : On ne connaît rien a priori sur les classes

En anglais : **Clustering** (unsupervised classification)

- **Classification supervisée** : On veut classer un nouvel individu à partir de la connaissance de classes définies a priori.

En anglais : **Classification**, **discriminant analysis**

Impossibilité d'une recherche exhaustive

- On n'abordera ici que des méthodes de "classification dure" : un individu n'appartient qu'à une seule classe

$$\forall i \in \{1, \dots, n\},\ \exists! k \in \{1, \dots, K\};\ i \in \mathcal{C}_k.$$

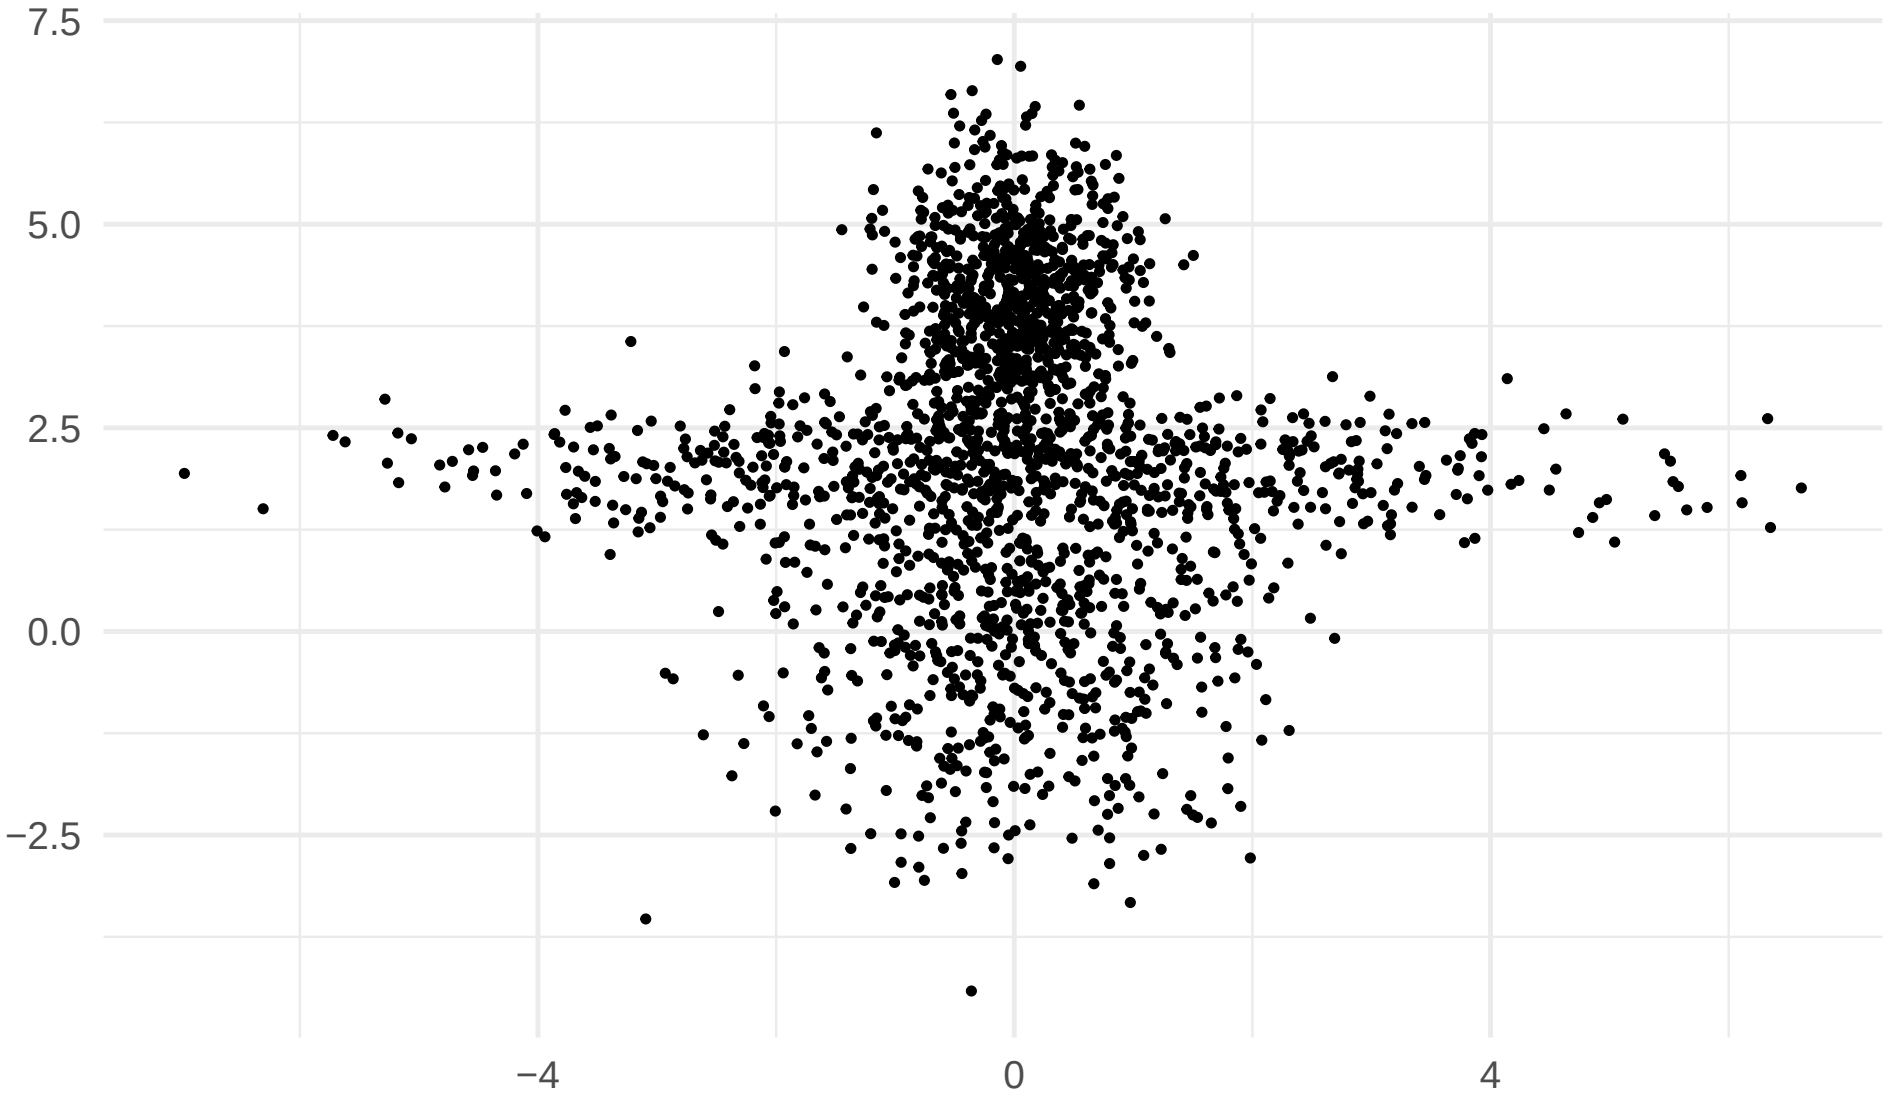
- Le nombre de partitions d'un ensemble de n individus en K classes (nombre de Stirling de 2ème espèce)

$$\frac{1}{K!} \sum_{j=0}^{K} (-1)^j (K-j)^n C_K^j$$

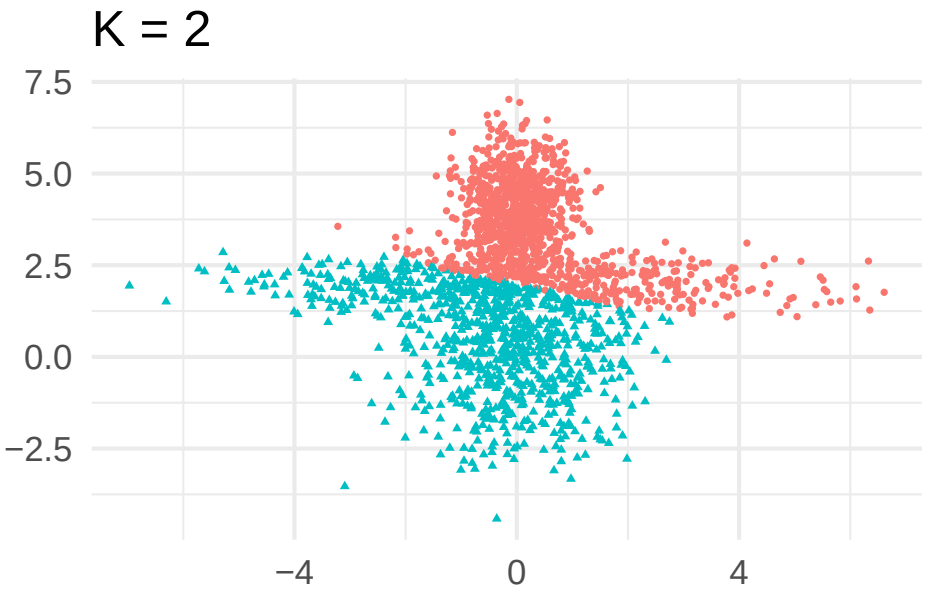
- $\simeq 10^{47}$ partitions de $n = 100$ individus en $K = 3$ classes
- $\simeq 10^{68}$ partitions de $n = 100$ individus en $K = 5$ classes

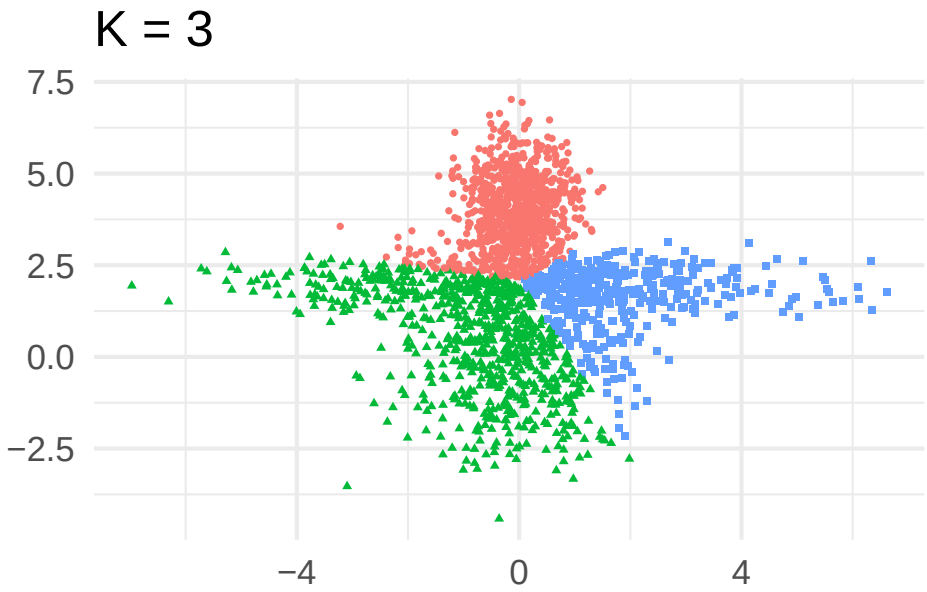
$\Longrightarrow$ **recherche exhaustive impossible**.

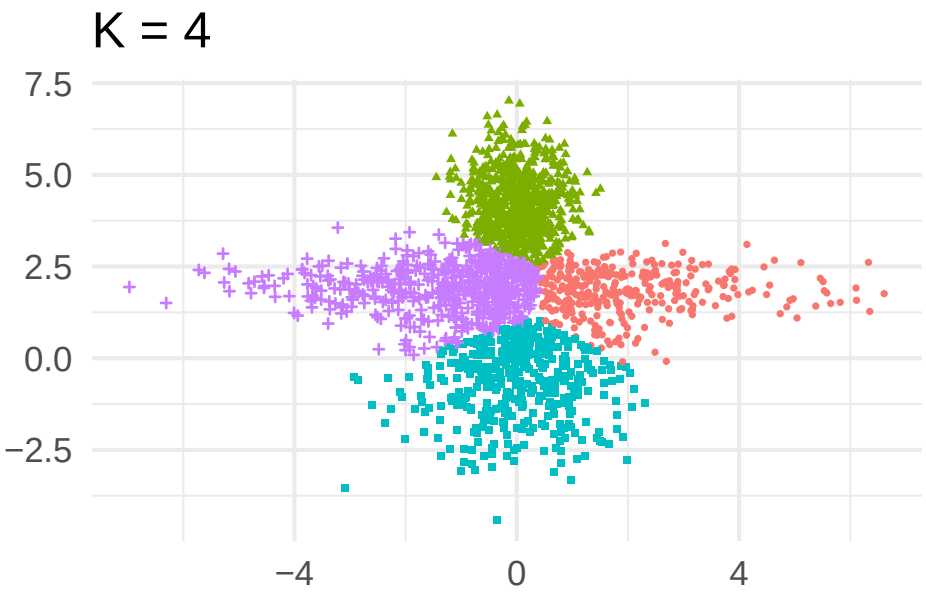
Combien de classes ?

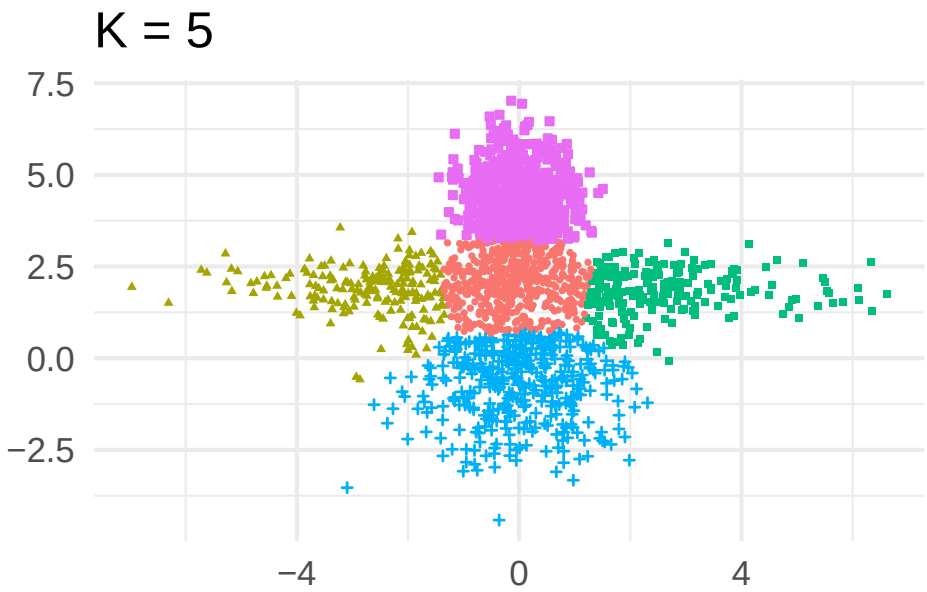


Combien de classes ?









Catégories de méthodes

- Les méthodes de clustering peuvent se différencier par
  - Type de "ressemblance" entre individus en terme de distance, de distribution de probabilité ...
  - Type de "partitionnement" : hard ou fuzzy clustering
- Grandes catégories de méthodes :
  - Méthodes fondées sur une distance : méthodes hiérarchiques, méthodes par partitionnement, ...
  - Méthodes basées sur la distribution probabiliste des données
  - Méthodes basées sur les réseaux de neurones
  - ...

Chapitre 0 - Introduction

1. Exemples introductifs
2. Principe du clustering
3. Outils pour comparer des clusterings
4. Suite du cours
5. References

Comment comparer deux clusterings ?

- On suppose que l'on a obtenu deux partitions à partir des mêmes données $\mathbf{X}$

$$\mathcal{P}_K = \{\mathcal{C}_1, \dots, \mathcal{C}_K\} \text{ et } \tilde{\mathcal{P}}_{\tilde{K}} = \{\tilde{\mathcal{C}}_1, \dots, \tilde{\mathcal{C}}_{\tilde{K}}\}$$

- Les nombres de classes K et $\tilde{K}$ peuvent être différents !

- Question : comment comparer ces deux classifications ?

Table de contingence

- On peut utiliser une **table de contingence** pour observer si des classes sont communes, des classes sont splittées, ...

	$\tilde{\mathcal{C}}_1$	$\tilde{\mathcal{C}}_2$	...	$\tilde{\mathcal{C}}_{\tilde{K}}$	Sums
$\mathcal{C}_1$	n_{11}	n_{12}	...	$n_{1\tilde{K}}$	a_1
$\mathcal{C}_2$	n_{21}	n_{22}	...	$n_{2\tilde{K}}$	a_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\mathcal{C}_K$	n_{K1}	n_{K2}	...	$n_{K\tilde{K}}$	a_K
Sums	b_1	b_2	...	$b_{\tilde{K}}$	n

avec $n_{k\ell} = \sharp \left\{ i \in \{1, \dots, n\};\ i \in \mathcal{C}_k \cap \tilde{\mathcal{C}}_\ell \right\}$, $a_k = \sum_{\ell=1}^{\tilde{K}} n_{k\ell}$ et $b_\ell = \sum_{k=1}^{K} n_{k\ell}$.

Exemple : Classification en 2 et 4 classes

```
        clust2
clust1    1   2   3   4 Sum
   1      3  50   0   0  53
   2     25   0  32  40  97
   Sum   28  50  32  40 150
```

Rand Index (RI)

$$RI(\mathcal{P}_K, \tilde{\mathcal{P}}_{\tilde{K}}) = \frac{A + D}{A + B + C + D}$$

avec

$A =$	Nb de paires d'indiv.	groupés	dans $\mathcal{P}_K$ et	groupés	dans $\tilde{\mathcal{P}}_{\tilde{K}}$
$B =$	" "	groupés	" "	séparés	" "
$C =$	" "	séparés	" "	groupés	" "
$D =$	" "	séparés	" "	séparés	" "

- RI = proportion de paires de points qui sont groupées de la même façon dans les deux partitions.

Adjusted Rand Index (ARI)

$$ARI(\mathcal{P}_K, \tilde{\mathcal{P}}_{\tilde{K}}) = \frac{U - W}{V - W}$$

avec

- $\mathsf{U} = \sum_{k\ell} \binom{n_{k\ell}}{2}$
- $\mathsf{V} = \frac{1}{2}\left[\sum_k \binom{a_k}{2} + \sum_\ell \binom{b_\ell}{2}\right]$
- $W = \text{indice obtenu en partitionnant les données au hasard}$
  $= \left[\sum_k \binom{a_k}{2} \sum_\ell \binom{b_\ell}{2}\right] / \binom{n}{2}$

Plus le ARI est proche de 1, plus les deux partitions se ressemblent

Exemples

- $n = 6$, $\mathcal{P}_2 = \{\{a, b, c\}, \{d, e, f\}\}$, $\tilde{\mathcal{P}}_2 = \{\{a, b\}, \{c, d, e, f\}\}$

	$\tilde{\mathcal{C}}_1 = \{a, b\}$	$\tilde{\mathcal{C}}_2 = \{c, d, e, f\}$	Somme
$\mathcal{C}_1 = \{a, b, c\}$	2	1	3
$\mathcal{C}_2 = \{d, e, f\}$	0	3	3
Somme	2	4	6

$RI(\mathcal{P}_2, \tilde{\mathcal{P}}_2) = \frac{10}{15} \approx 0,67$ et $ARI(\mathcal{P}_2, \tilde{\mathcal{P}}_2) = \frac{12}{37} \approx 0,32$

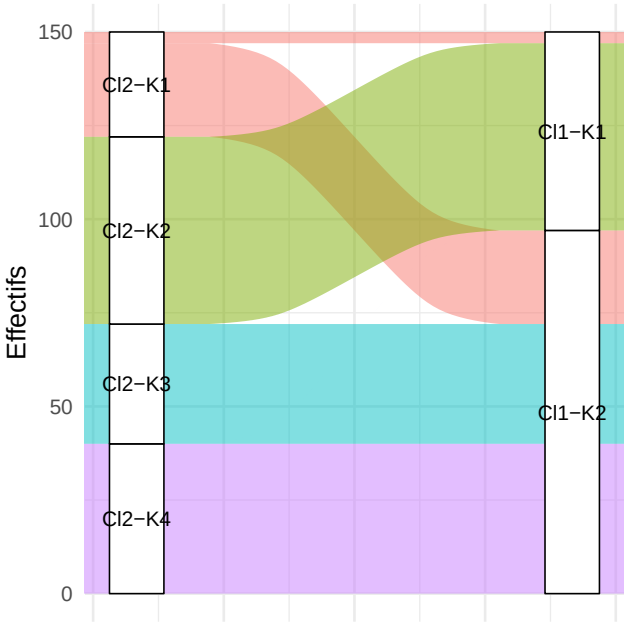
- $n = 6$, $\mathcal{P}_2 = \{\{a, b\}, \{c, d, e, f\}\}$, $\tilde{\mathcal{P}}_3 = \{\{a, b\}, \{c, d\}, \{e, f\}\}$

	$\tilde{\mathcal{C}}_1 = \{a, b\}$	$\tilde{\mathcal{C}}_2 = \{c, d\}$	$\tilde{\mathcal{C}}_3 = \{e, f\}$	Somme
$\mathcal{C}_1 = \{a, b\}$	2	0	0	2
$\mathcal{C}_2 = \{c, d, e, f\}$	0	2	2	4
Somme	2	2	2	6

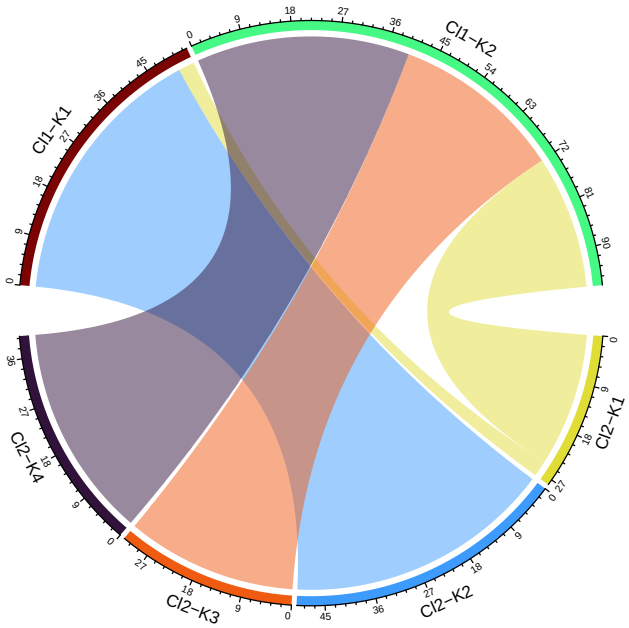
$RI(\mathcal{P}_2, \tilde{\mathcal{P}}_3) = \frac{11}{15} \approx 0,73$ et $ARI(\mathcal{P}_2, \tilde{\mathcal{P}}_3) = \frac{8}{18} \approx 0,44$

Quelques outils de visualisation

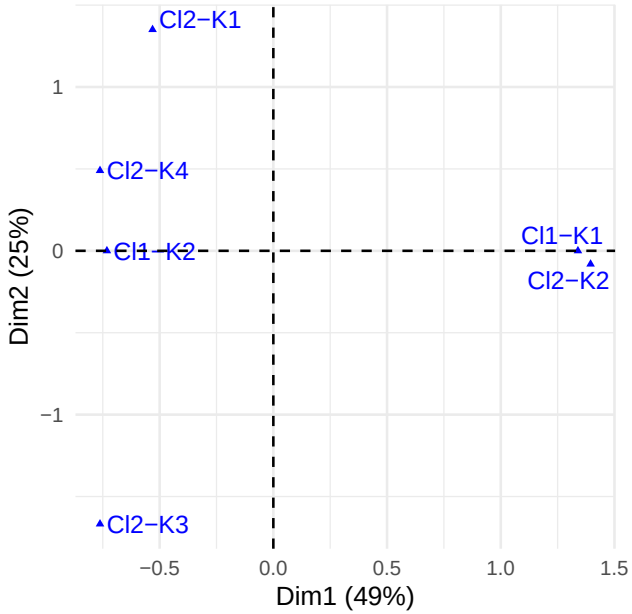
- Alluvial Diagram



- Chord Diagram



- AFCM



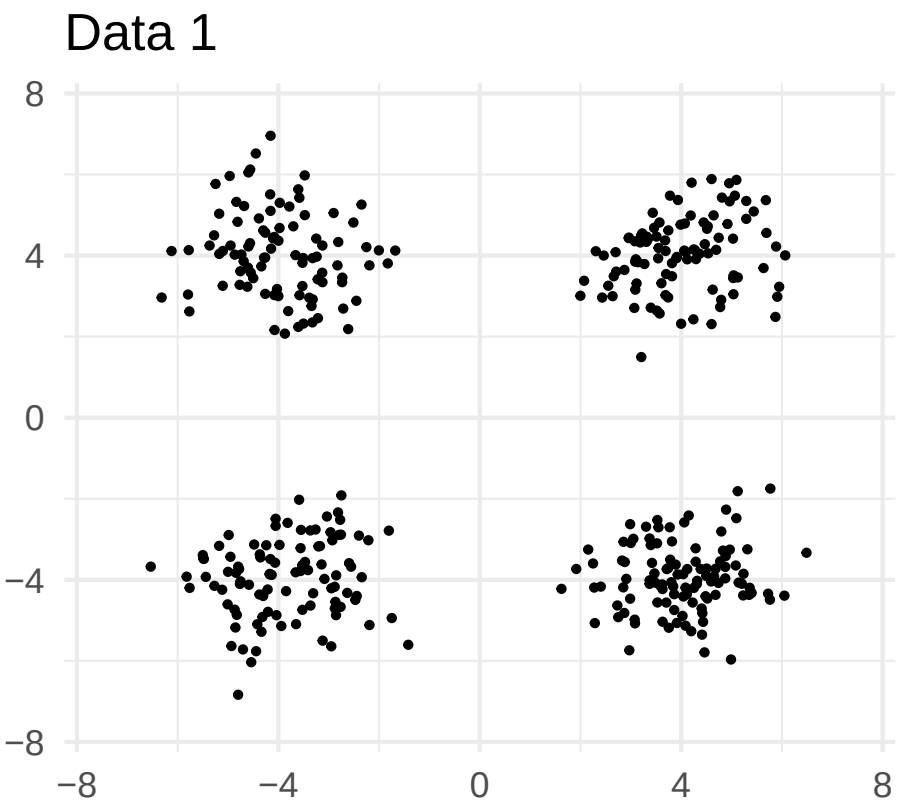
- Alluvial / Chord : chaque flux relie une classe de la partition 1 à une classe de la partition 2; son épaisseur = nombre d'individus communs (effectif $n_{k\ell}$ de la table de contingence)

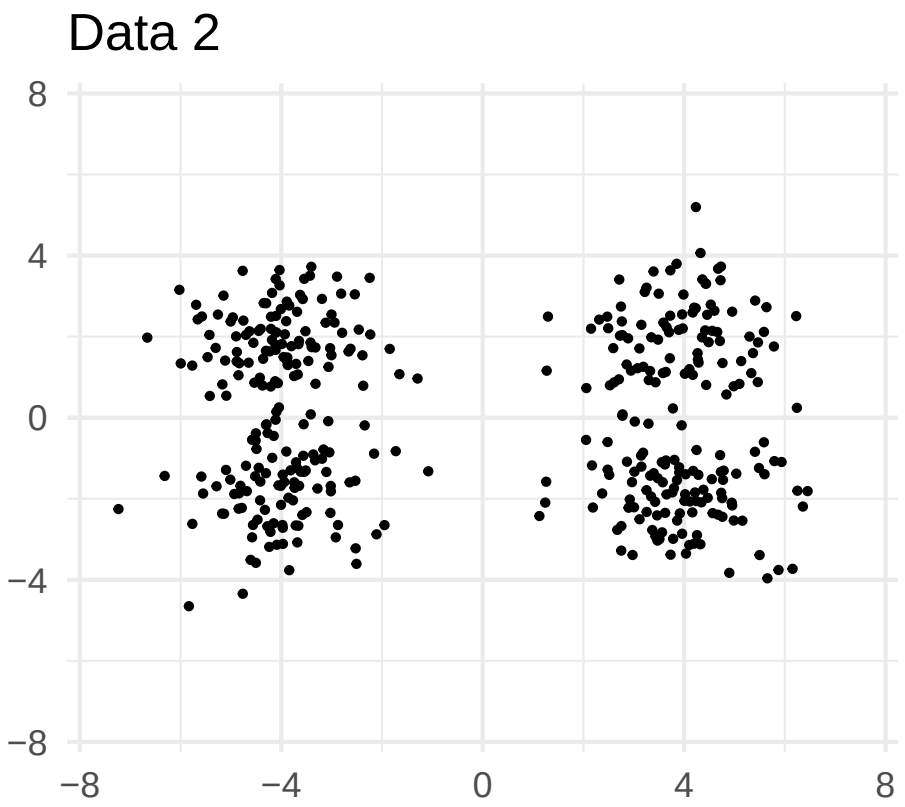
Chapitre 0 - Introduction

1. Exemples introductifs
2. Principe du clustering
3. Outils pour comparer des clusterings
4. Suite du cours
5. References

Données simulées Data1 et Data2

- Jeux de données jouet ($n = 400$, $p = 2$)





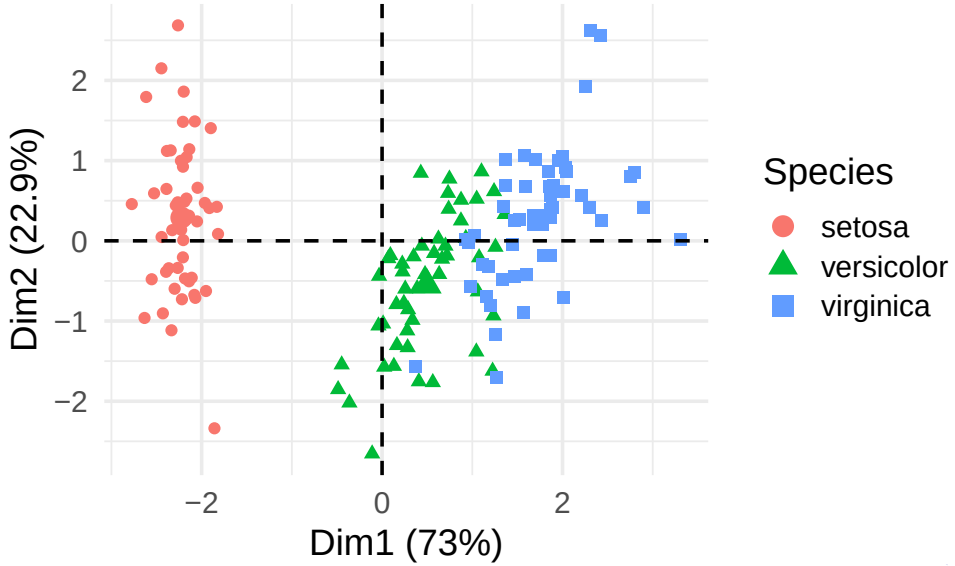
Données Iris (Anderson 1935)

- 3 espèces d'iris : setosa (50), versicolor (50) et virginica (50)
- Mesures en centimètres de longueur du sépale, largeur du sépale, longueur du pétale et largeur du pétale

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa



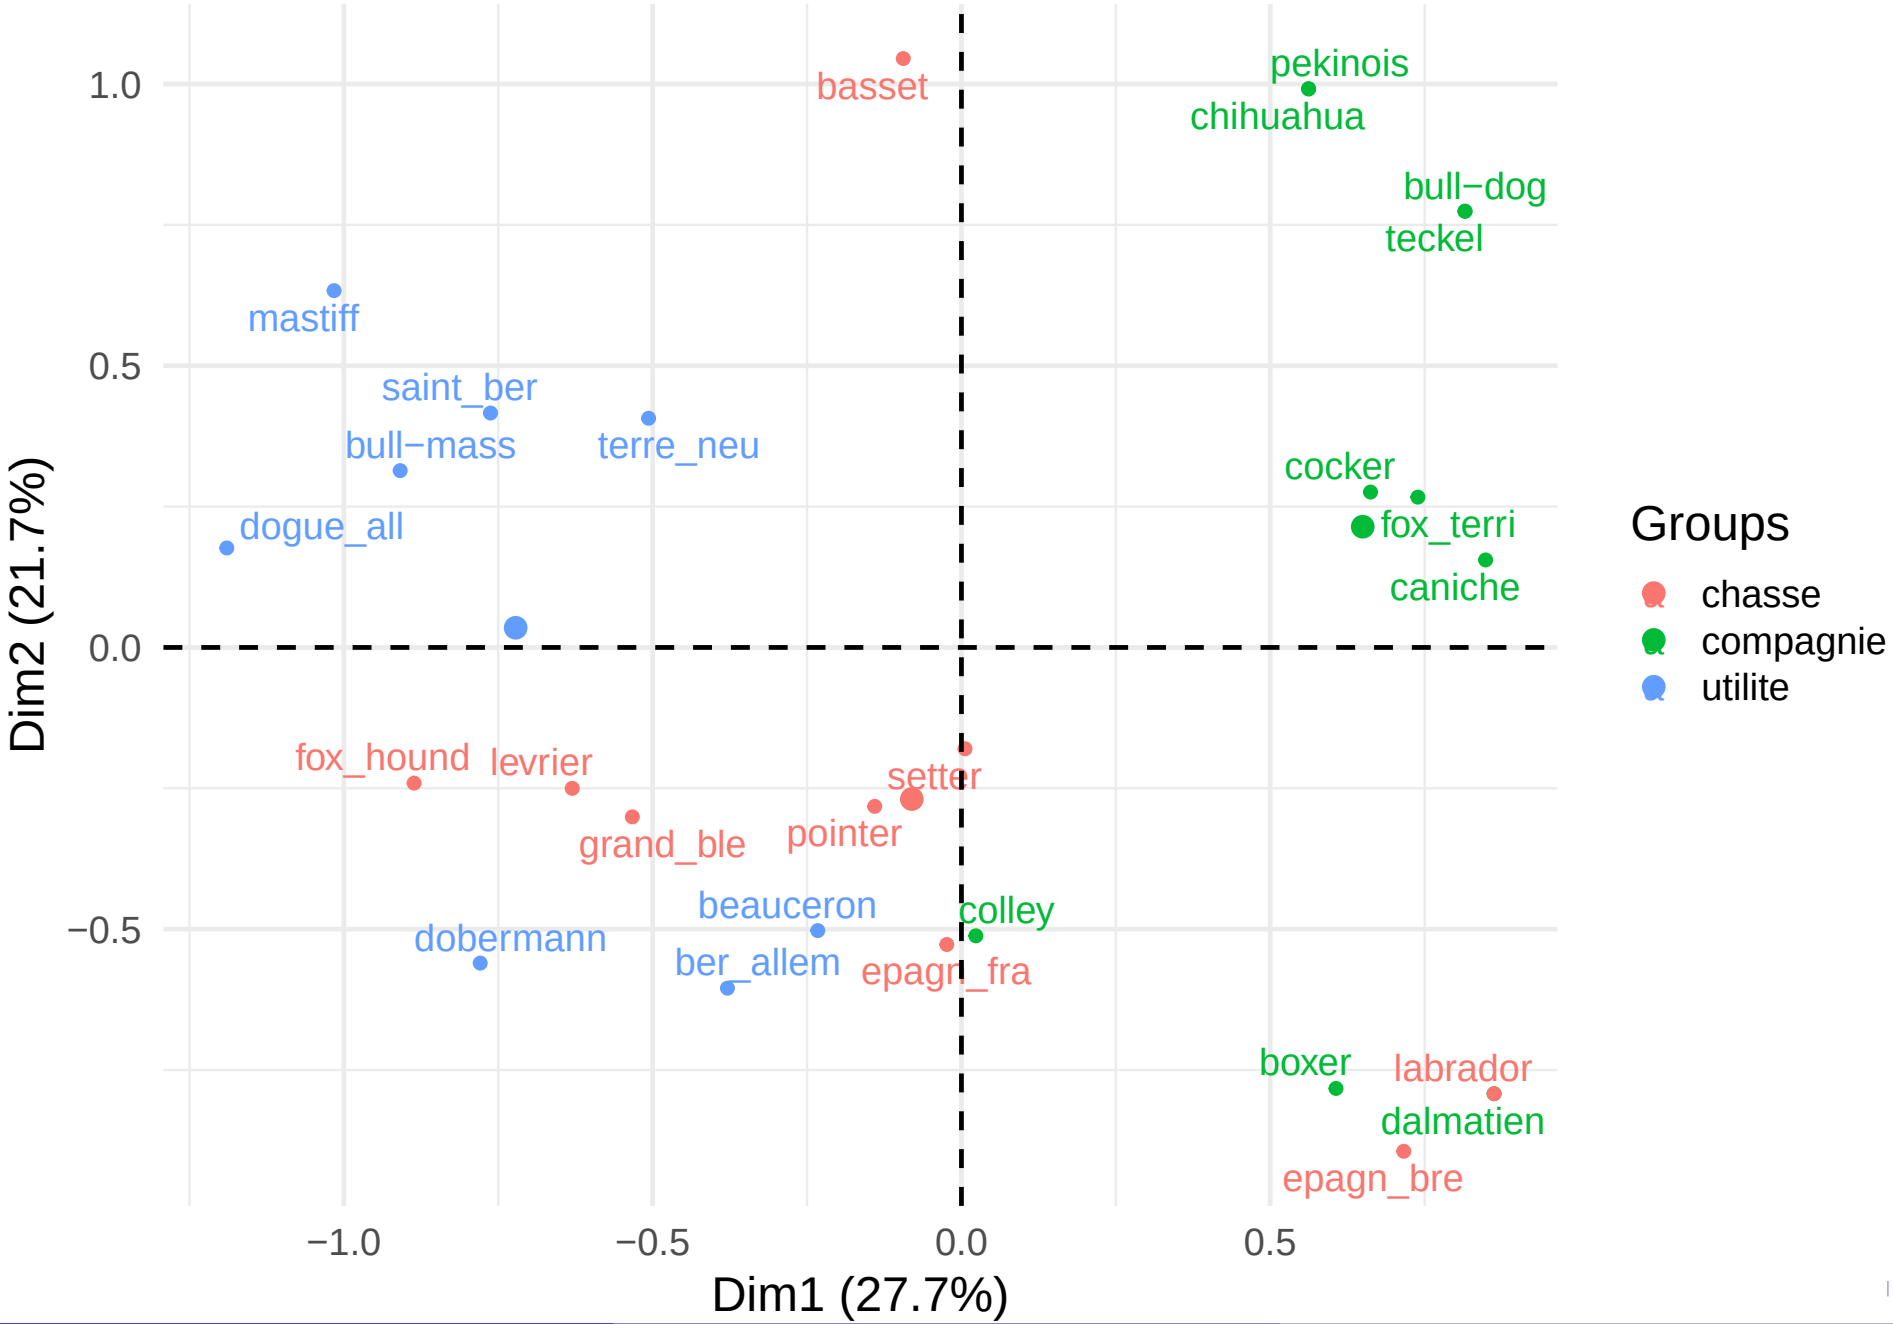
FIG. 2 – *I.setosa, I.versicolor, I.Virginica*



Données Races de chien (Bréfort 1982)

- Données : 27 races de chiens décrites par 6 variables
- 6 variables descriptives qualitatives :
  - taille : petite (1), moyenne (2), grande (3)
  - poids : petit (1), moyen (2), grand (3)
  - vélocité : petite (1), moyenne (2), grande (3)
  - intelligence : petite (1), moyenne (2), grande (3)
  - affection : faible (1), forte (2)
  - agressivité : faible (1), forte (2)
- 1 autre variable “fonction” : compagnie (1), chasse (2), utilité (3)

Données Races de chien



Données de maladie du coeur (Crowley and Hu 1977)

- $n = 270$ individus
- Variables binaires : sexe, sucre dans le sang à jeun $>$ 120mg/dl, angine induite par l'effort
- Variables nominales : douleurs à la poitrine (4 types), résultat électrocardiographique au repos (3 types), ...
- Variables réelles : âge, pression artérielle au repos, taux de cholestérol, fréquence cardiaque maximale atteinte, ...
- Données disponibles sur le site de l'UCI (Lien)

```
  Age Sex ChestPainType RestBloodPressure SerumCholestoral FastingBloodSugar
1  70   1             4                130               322                 0
2  67   0             3                115               564                 0
3  57   1             2                124               261                 0
  ResElectrocardiographic MaxHeartRate ExerciseInduced Slope MajorVessels Thal
1                       2          109                0     2            3    3
2                       2          160                0     2            0    7
3                       0          141                0     1            0    7
  Class
1     2
2     1
3     2
```

Chapitre 0 - Introduction

1. Exemples introductifs
2. Principe du clustering
3. Outils pour comparer des clusterings
4. Suite du cours
5. References

References

Anderson, Edgar. 1935. "The Irises of the Gaspe Peninsula." *Bull. Am. Iris Soc.* 59: 2–5.

Azzalini, Adelchi, and Adrian W Bowman. 1990. "A Look at Some Data on the Old Faithful Geyser." *Journal of the Royal Statistical Society: Series C (Applied Statistics)* 39 (3): 357–65.

Bréfort, A. 1982. "L'étude Des Races Canines à Partir de Leurs Caractéristiques Qualitatives." *Groupe HEC-Jouy En Josas*.

Crowley, John, and Marie Hu. 1977. "Covariance Analysis of Heart Transplant Survival Data." *Journal of the American Statistical Association* 72 (357): 27–36.

George, Karypis, and Han Eui-Hong. 1999. "Hierarchical Clustering Using Dynamic Modelling." *Computer* 4: 68–75.