Classification non supervisée (Clustering)

Classification non supervisée par modèles de mélange

Cathy Maugis-Rabusseau

4modIA / INSA Toulouse & ENSEEIHT

2026-2027

Chapitre 4 - Classification par modèles de mélange

1. Principe
2. Étape 2 : Estimation des paramètres
3. Étape 3 : Critère de sélection de modèle
4. Les mélanges gaussiens multivariés
5. En pratique
6. References

Hypothèses des mélanges finis

- Données : On observe n individus décrits par p variables

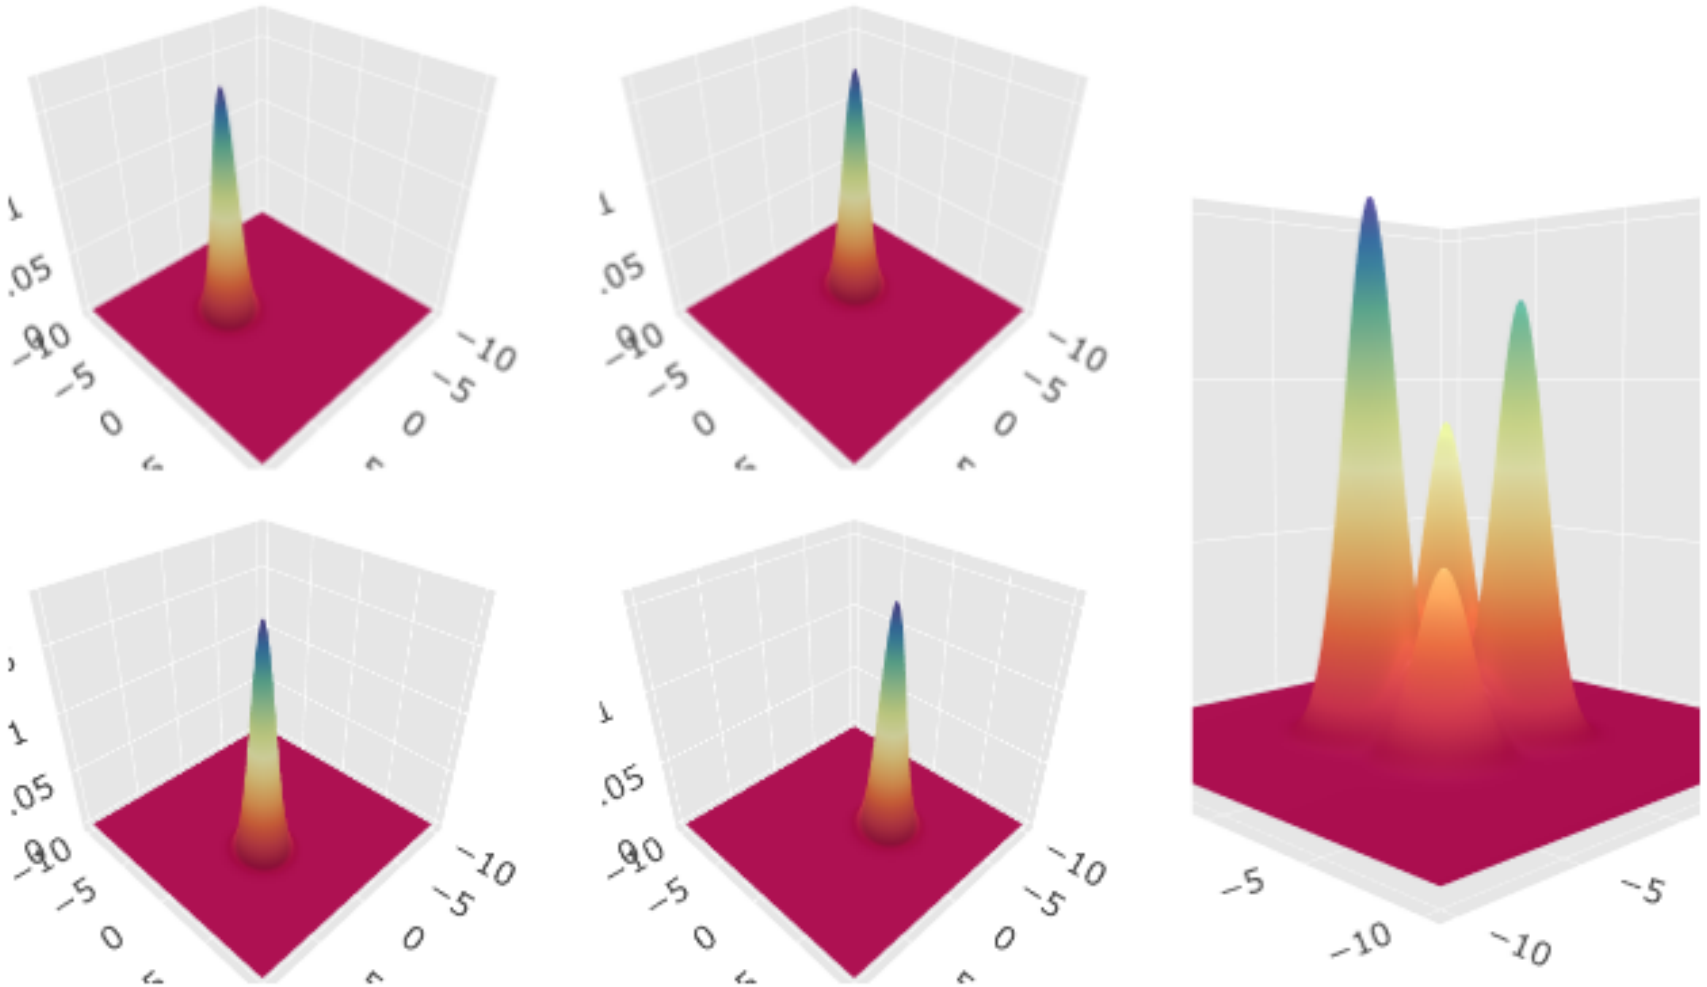
$$\underline{\mathbf{x}} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \quad \text{avec } x_i = (x_{i1}, \ldots, x_{ip}) \in \mathcal{X}$$

- On suppose que les données proviennent d'une population contenant plusieurs sous-populations

- Chaque sous-population est modélisée indépendamment des autres (choix d'une loi de distribution pour chaque sous-population).

- La population totale est alors vue comme un mélange de ces sous-populations. Le modèle résultant est un modèle de mélange fini.

Mélanges finis



Mélanges finis

- Un modèle de mélange à K composantes est de la forme

$$f(.|\theta_K) = \sum_{k=1}^{K} \pi_k f_k(.|\alpha_k)$$

  - $(\pi_1, \dots, \pi_K)$ sont les proportions du mélange

$$\forall k \in \{1, \dots, K\},\ \pi_k \in [0,1] \text{ et } \sum_{k=1}^{K} \pi_k = 1$$

  - $f_k(.|\alpha_k)$ est la densité de la $k$ème sous-population
  - $\theta_K = (\pi_1, \dots, \pi_K, \alpha_1, \dots, \alpha_K)$

- Le choix des f_k dépend de la nature des données

Structure cachée du modèle

- Données observées : $\underline{\mathbf{x}} = (x_1, \dots, x_n)$ avec $x_i = (x_{i1}, \dots, x_{ip})$
- Données manquantes (variables latentes) : $\underline{\mathbf{z}} = (z_1, \dots, z_n)$ avec $z_i = (z_{i1}, \dots, z_{iK})$ tel que $z_{ik} = \mathbb{1}_{i \in \mathcal{C}_k}$.
- Données complétées : $(\underline{\mathbf{x}}, \underline{\mathbf{z}}) = \{(x_1, z_1), \dots, (x_n, z_n)\}$
- Rem : $\underline{\mathbf{z}}$ définit une partition des données observées $\underline{\mathbf{x}}$: $\mathcal{C}_k = \{i \in \{1, \dots, n\}; z_{ik} = 1\}$ pour $k = 1, \dots, K$

Modèle génératif

- On suppose les proportions $\pi_1, \dots, \pi_K$ et les densités $f_1, \dots, f_k$ fixées
- Les données sont alors générées de la façon suivante :
  - $z_i = (z_{i1}, \dots, z_{iK}) \sim \mathcal{M}(1; \pi_1, \dots, \pi_K)$ (loi multinomiale)
    un individu i appartient à $\mathcal{C}_k$ avec probabilité π_k : $\mathbb{P}(z_{ik} = 1 | \theta_K) = \pi_k$
  - x_i est généré selon la densité f_k si i appartient à $\mathcal{C}_k$ $(z_{ik} = 1)$

$$f(x_i | z_{ik} = 1, \theta_K) = f_k(x_i | \alpha_k)$$

- Ainsi

$$f(x_i, z_i | \theta_K) = \prod_{k=1}^{K} \{\pi_k f_k(x_i | \alpha_k)\}^{z_{ik}}$$

et

$$f(x_i | \theta_K) = \sum_{k=1}^{K} f(x_i | z_{ik} = 1, \theta_K) \mathbb{P}(z_{ik} = 1 | \theta_K) = \sum_{k=1}^{K} \pi_k f_k(x_i | \alpha_k)$$

Les grandes étapes

1. Collection de modèles :

$$\forall K \in \mathbb{N}^\star,\ \mathcal{S}_K = \left\{ x \in \mathbb{R}^p \mapsto f(x|\theta_K) = \sum_{k=1}^{K} \pi_k f_k(.|\alpha_k) \right\}$$

Mélanges à K=2 classes | **Mélanges à K=3 classes** | **Mélanges à K=4 classes** | **Mélanges à K=5 classes** | ...

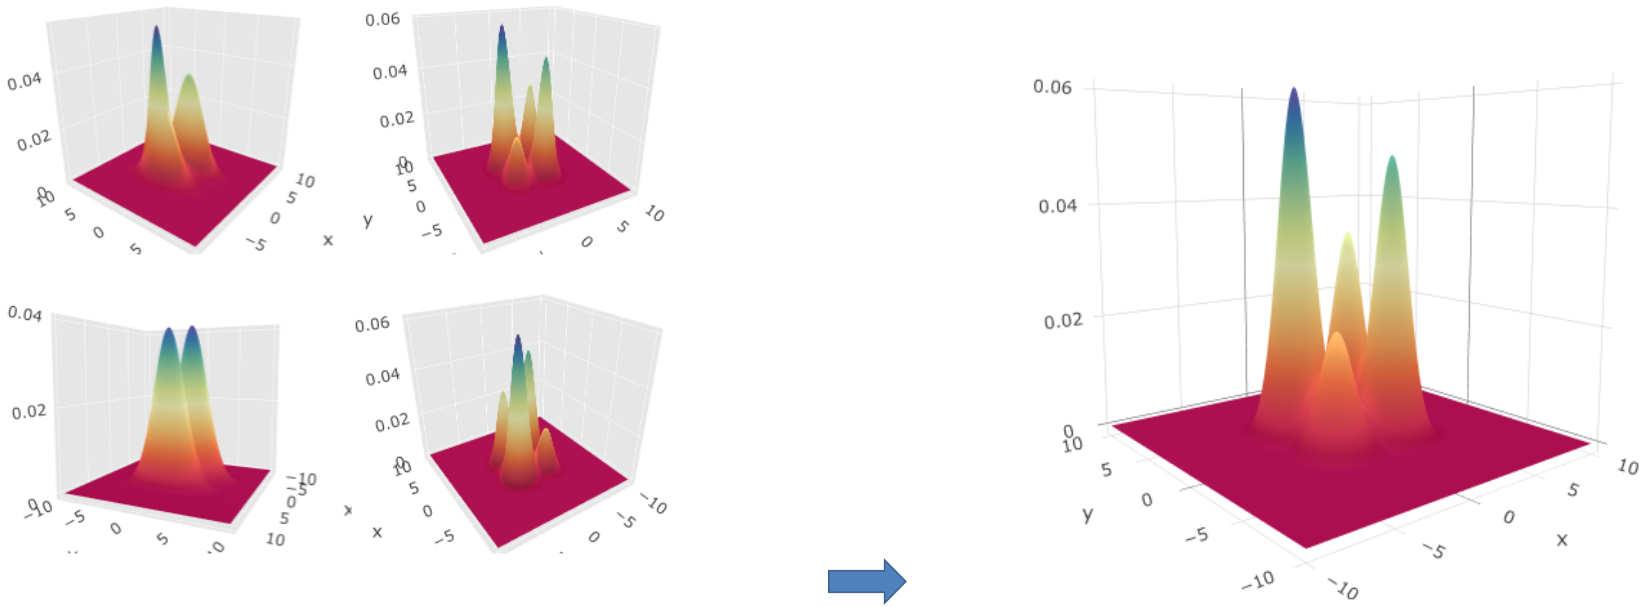
$\Rightarrow$ Choix initial de la modélisation

2. Dans chaque modèle $\mathcal{S}_K$: on détermine le mélange qui s'ajuste le mieux aux données: $f(.|\hat{\theta}_K)$

$\Rightarrow$ Besoin d'un algorithme d'estimation des paramètres $(\hat{\theta}_K)$

Les grandes étapes

3. Choisir le "meilleur" mélange parmi $f(.|\hat{\theta}_2), f(.|\hat{\theta}_3), \ldots, f(.|\hat{\theta}_{K_{\max}})$



$\Rightarrow$ Besoin d'un critère de sélection de modèles pour déterminer $\hat{K}$ et donc choisir $f(.|\hat{\theta}_{\hat{K}})$.

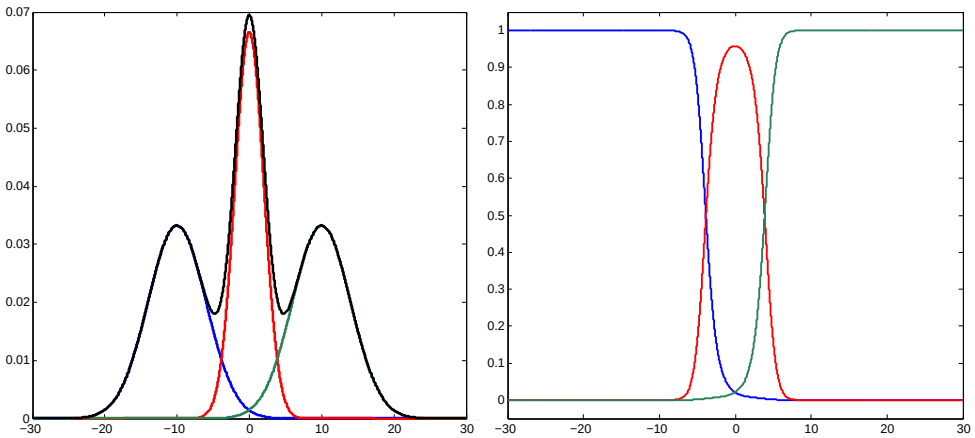
4. Règle du "MAP" pour en déduire une classification des données

Étape 4 : Règle du MAP

- Principe : chaque individu est affecté à la classe pour laquelle il a la plus forte probabilité d'appartenance conditionnellement à l'estimation des paramètres

- Probabilité conditionnelle d'appartenance de i à $\mathcal{C}_k$ avec le vecteur de paramètres θ

$$\begin{aligned} t_{ik}(\theta) &= \mathbb{P}(z_{ik}=1|x_i,\theta) \\ &= \frac{\pi_k f_k(x_i|\alpha_k)}{\sum_{\ell=1}^{K} \pi_\ell f_\ell(x_i|\alpha_\ell)} \end{aligned}$$

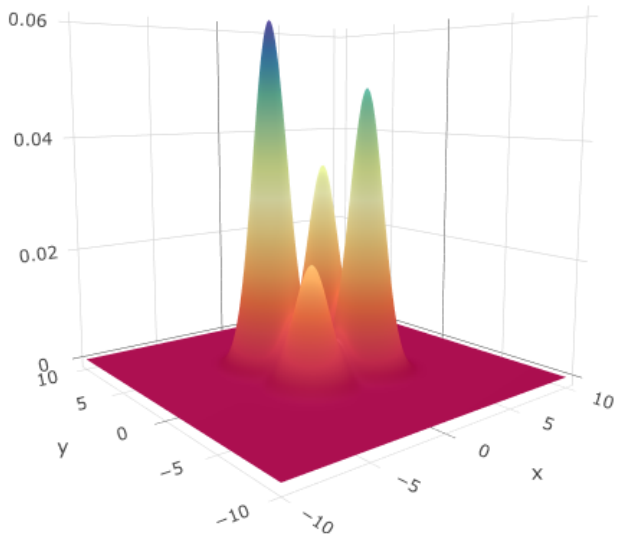


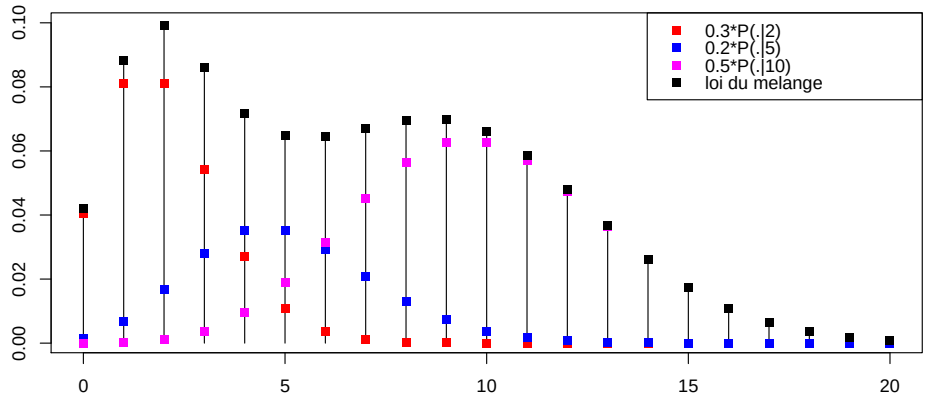
- Règle du maximum a posteriori (MAP) avec $\hat{\theta}_{\hat{K}}$:

$$i \in \mathcal{C}_k \text{ si } t_{ik}\left(\hat{\theta}_{\hat{K}}\right) > t_{i\ell}\left(\hat{\theta}_{\hat{K}}\right) \ \forall \ell \neq k$$

Étape 1 : Choix des distributions

- Données quantitatives : mélanges gaussiens, mélanges de Student, ….
- Données de comptages : mélanges de Poisson, de binomiales négatives, ...
- Données qualitatives : mélanges de multinomiales, ...
- Données compositionnelles : mélanges de Dirichlet, ...





Chapitre 4 - Classification par modèles de mélange

1. Principe
2. Étape 2 : Estimation des paramètres
3. Étape 3 : Critère de sélection de modèle
4. Les mélanges gaussiens multivariés
5. En pratique
6. References

Estimation du maximum de vraisemblance

- On désire déterminer le vecteur des paramètres $\theta_K = (\pi_1, \dots, \pi_K, \alpha_1, \dots, \alpha_K)$ qui **maximise la logvraisemblance** :

$$\mathcal{L}(\underline{\mathbf{x}}|\theta_K) = \mathcal{L}(x_1, \dots, x_n|\theta_K) = \sum_{i=1}^{n} \ln \left[\sum_{k=1}^{K} \pi_k f_k(x_i|\alpha_k) \right]$$

- Ce problème de maximisation ne possède généralement pas de solution analytique

- $\Rightarrow$ Algorithme d'optimisation pour approcher $\hat{\theta}_K$

Vraisemblance classifiante

- Algorithme s'appuyant sur la notion de données complétées :

$$(\underline{\mathbf{x}}, \underline{\mathbf{z}}) = \{\underbrace{(x_1, \dots, x_n)}_{\text{données observées}}, \underbrace{(z_1, \dots, z_n)}_{\text{variables latentes}}\}$$

- Logvraisemblance des données complétées ou logvraisemblance classifiante :

$$\begin{aligned}
\mathcal{L}(\underline{\mathbf{x}}, \underline{\mathbf{z}}|\theta_K) &= \ln\left[f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|\theta_K)\right] \\
&= \ln\left[\prod_{i=1}^{n}\prod_{k=1}^{K}\left\{\pi_k f_k(x_i|\alpha_k)\right\}^{z_{ik}}\right] \\
&= \sum_{i=1}^{n}\sum_{k=1}^{K} z_{ik}\left\{\ln(\pi_k) + \ln(f_k(x_i|\alpha_k))\right\}
\end{aligned}$$

Algorithme EM (Dempster, Laird, and Rubin 1977)

- EM = Expectation Maximization
- Maximisation par itérations successives de l'espérance de la logvraisemblance classifiante conditionnellement aux observations et une valeur courante des paramètres $\theta^{(r)}$:

$$\begin{aligned}\mathcal{Q}\left(\theta_K|\theta_K^{(r)}\right) &:= \mathbb{E}\left[\ln(f(\underline{\mathbf{x}},\underline{\mathbf{z}}|\theta_K)|\underline{\mathbf{x}},\theta_K^{(r)}\right] \\ &= \sum_{i=1}^{n}\sum_{k=1}^{K}\mathbb{E}\left[z_{ik}|\underline{\mathbf{x}},\theta_K^{(r)}\right]\{\ln(\pi_k)+\ln(f_k(x_i|\alpha_k))\}\end{aligned}$$

avec $\mathbb{E}\left[z_{ik}|\underline{\mathbf{x}},\theta_K^{(r)}\right] = \mathbb{P}\left(z_{ik}=1|\underline{\mathbf{x}},\theta_K^{(r)}\right) = t_{ik}(\theta_K^{(r)}) := t_{ik}^{(r)}$

Algorithme EM

- Initialisation: $\theta_K^{(0)}$
- Étape E: Calcul de $\mathcal{Q}\left(\theta_K|\theta_K^{(r)}\right) \Leftrightarrow$ calcul des $t_{ik}^{(r)}$

$$t_{ik}^{(r)} = \mathbb{P}\left(z_{ik}=1|x_i,\theta_K^{(r)}\right) = \frac{\pi_k^{(r)} f_k\left(x_i|\alpha_k^{(r)}\right)}{\sum_{\ell=1}^{K} \pi_\ell^{(r)} f_\ell\left(x_i|\alpha_\ell^{(r)}\right)}$$

- Étape M: Déterminer $\theta_K^{(r+1)} = \underset{\theta_K\in\Theta_K}{\text{argmax}}\ \mathcal{Q}\left(\theta_K|\theta_K^{(r)}\right)$

$$\begin{cases} \pi_k^{(r+1)} = \frac{1}{n}\sum_{i=1}^{n} t_{ik}^{(r)} \\ \\ (\alpha_1^{(r+1)},\ldots,\alpha_K^{(r+1)}) = \underset{(\beta_1,\ldots,\beta_K)}{\text{argmax}} \sum_{i=1}^{n}\sum_{k=1}^{K} t_{ik}^{(r)} \ln[f_k(x_i|\beta_k)] \end{cases}$$

Caractéristiques de l'algorithme EM

- Propriétés :

Propriété 1

À chaque itération de l'algorithme EM, la logvraisemblance croît.

Propriété 2

L'algorithme EM converge mais pas nécessairement vers le maximum global de la logvraisemblance.

- En pratique :
  - Facile à mettre en œuvre
  - Parfois lent à converger (en particulier lorsque les composants sont très mélangés)
  - Sensible à l'initialisation (i.e. au choix de $\theta_K^{(0)}$)

Exemple : mélange gaussien unidim. à 2 composantes

- $x \mapsto \beta\phi(x|\mu_1,\sigma_1^2) + (1-\beta)\phi(x|\mu_2,\sigma_2^2)$ avec

$$\phi(x|\mu_k,\sigma_k^2) = (2\pi\sigma_k^2)^{-\frac{1}{2}} \exp\left[-\frac{(x-\mu_k)^2}{2\sigma_k^2}\right]$$

- Étape E :

$$t_{i1}^{(r)} = \frac{\beta^{(r)}\phi(x_i|\mu_1^{(r)},\sigma_1^{2\,(r)})}{\beta^{(r)}\phi(x_i|\mu_1^{(r)},\sigma_1^{2\,(r)}) + (1-\beta^{(r)})\phi(x_i|\mu_2^{(r)},\sigma_2^{2\,(r)})} = 1 - t_{i2}^{(r)}$$

- Étape M :

$$\beta^{(r+1)} = \frac{1}{n}\sum_{i=1}^{n} t_{i1}^{(r)} \qquad \mu_k^{(r+1)} = \frac{\sum_{i=1}^{n} t_{ik}^{(r)} x_i}{\sum_{i=1}^{n} t_{ik}^{(r)}}$$

$$\sigma_k^{2\,(r+1)} = \frac{\sum_{i=1}^{n} t_{ik}^{(r)} \left(x_i - \mu_k^{(r+1)}\right)^2}{\sum_{i=1}^{n} t_{ik}^{(r)}}$$

Algorithme SEM (Celeux and Diebolt 1985)

- SEM = Stochastic EM
- Ajout d'une étape S de classification aléatoire
  - Étape E: Calcul des $t_{ik}^{(r)}$
  - Étape S: Tirage au hasard d'une classe pour chaque individu : on simule les $\hat{z}_{ik}^{(r)}$ selon $\mathcal{M}\left(1; t_{i1}^{(r)}, \ldots, t_{iK}^{(r)}\right)$
  - Étape M: On actualise les paramètres en remplaçant $t_{ik}^{(r)}$ par $\hat{z}_{ik}^{(r)}$.

Autres variantes de l'algorithme EM

- SAEM (Stochastic Approximation EM) (Delyon, Lavielle, and Moulines 1999)

Compromis entre EM et SEM. L'importance des tirages aléatoires diminue avec le temps.

$$\theta^{(r+1)} = \gamma_r \, \theta_{\text{SEM}}^{(r+1)} + (1-\gamma_r) \, \theta_{\text{EM}}^{(r+1)}$$

où $\gamma_0 = 1$ et $(\gamma_r)_{r \geq 0}$ est décroissante.

- MCEM (Monte Carlo EM) (Wei and Tanner 1990)
  - Étape Monte Carlo E: Simulation de M répétitions de $\underline{\mathbf{z}}$, notées $\underline{\mathbf{z}}'_1, \ldots, \underline{\mathbf{z}}'_M$ selon la distribution conditionnelle de $\underline{\mathbf{z}}|\underline{\mathbf{x}}, \theta^{(r)}$
  - Étape M: Maximisation en θ de

$$\theta \mapsto \frac{1}{M} \sum_{m=1}^{M} \ln[f(\underline{\mathbf{x}}, \underline{\mathbf{z}}'_m|\theta)]$$

qui approche $\mathcal{Q}(\theta_K|\theta_K^{(r)})$.

Approche par MV classifiante

- Approche CMV : $\underline{\mathbf{z}}$ est vu comme un paramètre à estimer
- Estimation simultanée de θ et $\underline{\mathbf{z}}$ en maximisant la logvraisemblance classifiante :

$$\mathcal{L}(\underline{\mathbf{x}}, \underline{\mathbf{z}}|\theta_K) = \sum_{i=1}^{n}\sum_{k=1}^{K} z_{ik} \left\{\ln(\pi_k) + \ln(f_k(x_i|\alpha_k))\right\}$$

- Cette approche revient à chercher une partition telle que chaque classe $\mathcal{C}_k$ soit assimilable à un sous-échantillon issu de la loi $f_k(.|\alpha_k)$.

Algorithme CEM (Celeux and Govaert 1992)

- CEM = Classification EM
- Étapes de l'algorithme :
  - Étape E: Calcul des $t_{ik}^{(r)}$
  - Étape C: détermination d'une partition des données $\underline{\mathbf{x}}$ par la règle du MAP

$$\hat{z}_{ik}^{(r)} = \begin{cases} 1 & \text{si } t_{ik}^{(r)} > t_{i\ell}^{(r)}, \forall \ell \neq k \\ 0 & \text{sinon} \end{cases}$$

- Étape M: On actualise les paramètres en remplaçant $t_{ik}

Caractéristiques de l'algorithme CEM

- CEM vise à maximiser la vraisemblance complétée et non la vraisemblance.
- CEM converge en un nombre fini d'itérations contrairement à EM
- CEM produit des estimateurs biaisés des paramètres du mélange
- CEM est un algorithme de type K-means (voir exercice)

Initialisation

- Les algorithmes de type EM sont sensibles à l'initialisation
- Stratégie en Search/Run/Select:
  - Choix de M positions initiales (RANDOM, CEM, SEM, quelques runs de EM)
  - Quelques itérations de l'algorithme pour chacune des positions
  - Sélection de la position donnant la plus grande vraisemblance (ou vraisemblance classifiante).

Chapitre 4 - Classification par modèles de mélange

1 Principe

2 Étape 2 : Estimation des paramètres

3 Étape 3 : Critère de sélection de modèle

4 Les mélanges gaussiens multivariés

5 En pratique

6 References

Critères asymptotiques de sélection

$$\hat{K} = \underset{K}{\text{argmin}}\ \text{crit}(K) = \underset{K}{\text{argmin}}\ -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \text{pen}(K)$$

- **AIC** (Akaike Information Criterion) (Akaike 1973)
$$\text{crit}(K) = -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \nu_K$$

- **BIC** (Bayesian Information Criterion) (Schwarz 1978)
$$\text{crit}(K) = -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n)$$

- **ICL** (Integrated Completed Likelihood) (Biernacki, Celeux, and Govaert 2000)
$$\text{crit}(K) = -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n) + \text{Ent}(K)$$

où ν_K est nombre de paramètres libres des mélanges de $\mathcal{S}_K$

$\text{Ent}(K) = -\sum_{i=1}^{n}\sum_{k=1}^{K} \hat{z}_{ik}\ln[t_{ik}(\hat{\theta}_K)]$ est un terme d'entropie

Critère AIC (Akaike 1973)

- Critère AIC :

$$\text{crit}(K) = -\mathcal{L}(\underline{\mathbf{x}}|\widehat{\theta}_K) + \nu_K$$

- Critère pour réaliser un compromis en terme de “biais-variance”
- Asymptotiquement, AIC retient le modèle minimisant l’écart de Kullback moyen avec la vraie loi inconnue
- Dans le cadre des modèles de mélanges finis, AIC a tendance à sous-pénaliser

Critère BIC (Schwarz 1978)

- Critère fondé sur la maximisation de la vraisemblance intégrée :

$$\hat{K} = \underset{K}{\text{argmax}}\ f(\underline{\mathbf{x}}|K)$$

où $f(\underline{\mathbf{x}}|K) = \int_{\Theta_K} f(\underline{\mathbf{x}}|\theta, K)\Pi(\theta|K)d\theta$ est la vraisemblance intégrée et $\Pi(\theta|K)$ est un prior non informatif.

- Approximation asymptotique : $f(\underline{\mathbf{x}}|K) \approx \ln\left[f(\underline{\mathbf{x}}|\hat{\theta}_K)\right] - \frac{\nu_K}{2}\ln(n)$

- Bayesian Information Criterion (BIC) :

$$\hat{K} = \underset{K}{\text{argmin}}\ \left\{-\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n)\right\}$$

- Asymptotiquement, BIC sélectionne le modèle minimisant l'écart de Kullback avec la vraie loi. En ce sens, BIC est convergent si le vrai modèle est dans la liste des modèles

Critère ICL (Biernacki, Celeux, and Govaert 2000)

- $\hat{K} = \underset{K}{\text{argmax}}\ f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|K)$ où $f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|K) = \int_{\Theta_K} f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|\theta, K)\Pi(\theta|K)d\theta$ est la vraisemblance complète intégrée et $\Pi(\theta|K)$ est un prior non informatif.

- Approximation asymptotique de type BIC:

$$f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|K) \approx \ln\left[f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|\hat{\theta}^{\star}_K)\right] - \frac{\nu_K}{2}\ln(n)$$

où $\hat{\theta}^{\star}_K = \underset{\theta_K \in \Theta_K}{\text{argmax}}\ f(\underline{\mathbf{x}}, \underline{\mathbf{z}}|\theta_K)$.

- Problème : $\underline{\mathbf{z}}$ est inconnu et donc $\hat{\theta}^{\star}_K$ est inaccessible $\rightsquigarrow$ $\hat{\underline{\mathbf{z}}} = \text{MAP}(\hat{\theta}_K)$

- Integrated Completed Likelihood :

$$\hat{K} = \underset{K}{\text{argmin}}\ \left\{-\mathcal{L}(\underline{\mathbf{x}}, \hat{\underline{\mathbf{z}}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n)\right\}$$

Différence entre ICL et BIC

- $\text{BIC}(K) = -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n)$

- Relation entre ICL et BIC

$$\begin{aligned}
\text{ICL}(K) &= -\mathcal{L}(\underline{\mathbf{x}}, \underline{\hat{\mathbf{z}}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n) \\
&= -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + \frac{\nu_K}{2}\ln(n) + \text{Ent}(K) \\
&= \text{BIC}(K) + \text{Ent}(K)
\end{aligned}$$

où l'entropie est définie par

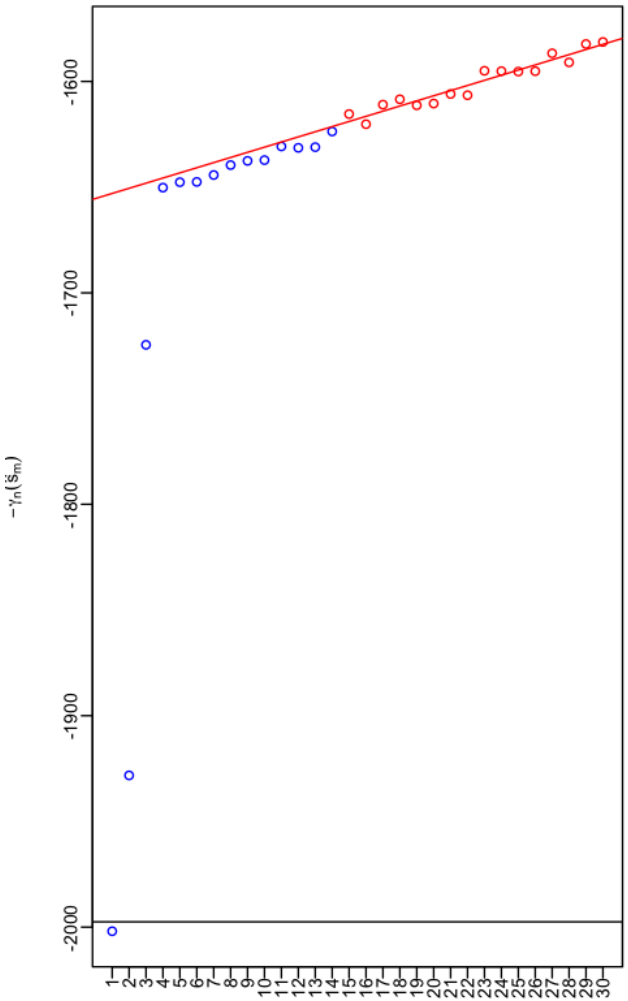
$$\text{Ent}(K) = -\sum_{i=1}^{n}\sum_{k=1}^{K} \hat{z}_{ik} \ln[t_{ik}(\hat{\theta}_K)]$$

Alternative avec l'heuristique de pente

- Critère non-asymptotique

$$\hat{K} = \underset{K}{\text{argmin}}\ \text{crit}(K) = \underset{K}{\text{argmin}}\ -\mathcal{L}(\underline{\mathbf{x}}|\hat{\theta}_K) + 2\kappa D_K$$

- Nécessite de déterminer la quantité D_K qui représente la dimension du modèle $\mathcal{S}_K$
- Calibration de la pente inconnue κ



Chapitre 4 - Classification par modèles de mélange

1 Principe

2 Étape 2 : Estimation des paramètres

3 Étape 3 : Critère de sélection de modèle

4 Les mélanges gaussiens multivariés

5 En pratique

6 References

Mélanges gaussiens multivariés

- Données quantitatives : $x_i \in \mathbb{R}^p$
- Les observations sont supposées issues d'un échantillon de loi

$$f(.|\theta_{K,m}) = \sum_{k=1}^{K} \pi_{k,m} \ \phi(.|\mu_k, \Sigma_{k,m})$$

  - $\phi(.|\mu_k, \Sigma_k)$ la densité d'une loi gaussienne multivariée $\mathcal{N}_p(\mu_k, \Sigma_k)$
  - $\theta_{K,m} = (\pi_{1,m}, \dots, \pi_{K,m}, \mu_1, \dots, \mu_K, \Sigma_{1,m}, \dots, \Sigma_{K,m})$
- Collection de modèles: $\left(\mathcal{S}_{(K,m)}\right)_{(K,m)\in\mathbb{N}^\star\times\mathcal{M}}$ avec
  - $\mathcal{S}_{(K,m)} = \left\{x \in \mathbb{R}^p \mapsto f(x|\theta_{K,m}); \theta_{K,m} \in \Theta_{K,m}\right\}$
  - $\mathcal{M}$ = ensemble de formes de mélanges gaussiens

Formes m des mélanges gaussiens

- La décomposition en valeurs propres des matrices variance Σ_k :

$$\Sigma_k = L_k D_k A_k D_k'$$

  - Σ_k est une matrice définie positive de taille $p \times p$
  - $L_k = |\Sigma_k|^{1/p}$ (le volume)
  - D_k la matrice des vecteurs propres de Σ_k (l'orientation)
  - A_k la matrice diagonale des v.p. normalisées de Σ_k (la forme)

- $\Rightarrow$ 3 familles (sphérique, diagonale, générale) $\Rightarrow$ 14 formes

- Proportions supposées égales ou libres

$\Rightarrow$ 28 formes de mélanges gaussiens possibles

Exemple dans $\mathbb{R}^2$

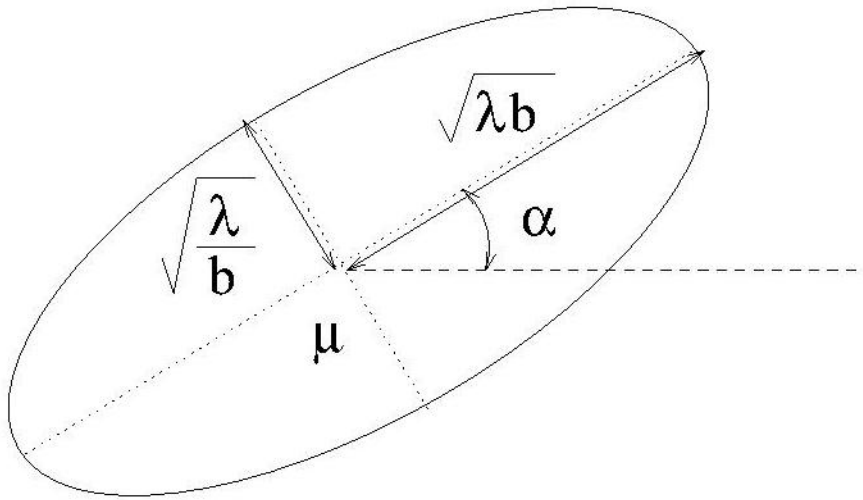
- D est une matrice de rotation définie par un angle α

$$D = \begin{pmatrix} \cos(\alpha) & \sin(\alpha) \\ -\sin(\alpha) & \cos(\alpha) \end{pmatrix}$$

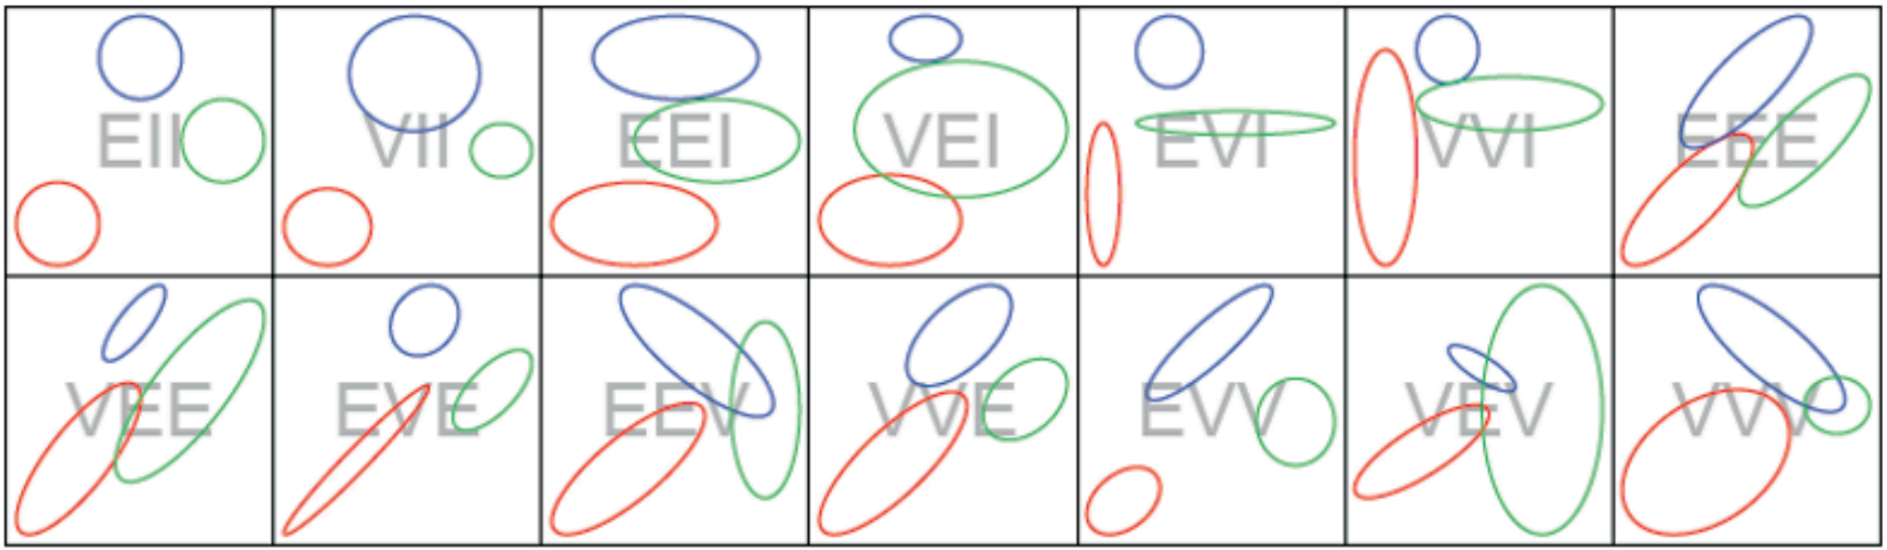
- A est une matrice diagonale de termes diagonaux b et $\frac{1}{b}$

$$A = \begin{pmatrix} b & 0 \\ 0 & \frac{1}{b} \end{pmatrix}$$

- Ellipse d'équidensité ($L = \lambda$ =volume)



Formes m des mélanges gaussiens



Bouveyron et al. (2019)

Lien entre GMM et K-means

La méthode des K-means est un cas particulier des GMM :

- Collection de modèles : mélanges gaussiens sphériques

+

- Estimer les paramètres avec l'algorithme CEM

On peut alors utiliser les critères de sélection de modèles (Étape 3) pour choisir le nombre de classes.

Chapitre 4 - Classification par modèles de mélange

1 Principe

2 Étape 2 : Estimation des paramètres

3 Étape 3 : Critère de sélection de modèle

4 Les mélanges gaussiens multivariés

5 En pratique

6 References

Quelques librairies avec 

- Librairie `mclust` [Scrucca et al.]

mixtures of multivariate Gaussian

- Librairie `Rmixmod` [Biernacki et al.]

mixtures of multivariate Gaussian or multinomial components

- Librairie `mixture` [McNicholas P.D. et al.]

Gaussian, Student's t, generalized hyperbolic, variance-gamma or skew-t mixtures

- Librairie `movMF` [Horbik and Grün]

mixtures of von Mises-Fisher distributions

- et bien d'autres !

Et avec 

- `sklearn.mixture.GaussianMixture(.)`
- Package `PyMix` [Georgi et al., http://www.pymix.org/]
- Package `Pymixmod` (la version python de mixmod)
- `Multinomial_Mixture_Model` [https://github.com/diningphil/Multinomial_Mixture_Model]
- `studenttmixture` [https://github.com/jlparki/mix_T]
- ...

Exemple des iris avec 

- Utilisation du package `mclust`
- Sélection de modèles avec le critère BIC

```
data(iris)
library(mclust)
resmclust<-Mclust(iris[,-5],G=1:9,modelNames = c("EEE","VEE","EVV","VVV"))
summary(resmclust)
```

```
----------------------------------------------------
Gaussian finite mixture model fitted by EM algorithm
----------------------------------------------------

Mclust VVV (ellipsoidal, varying volume, shape, and orientation) model with 2
components:

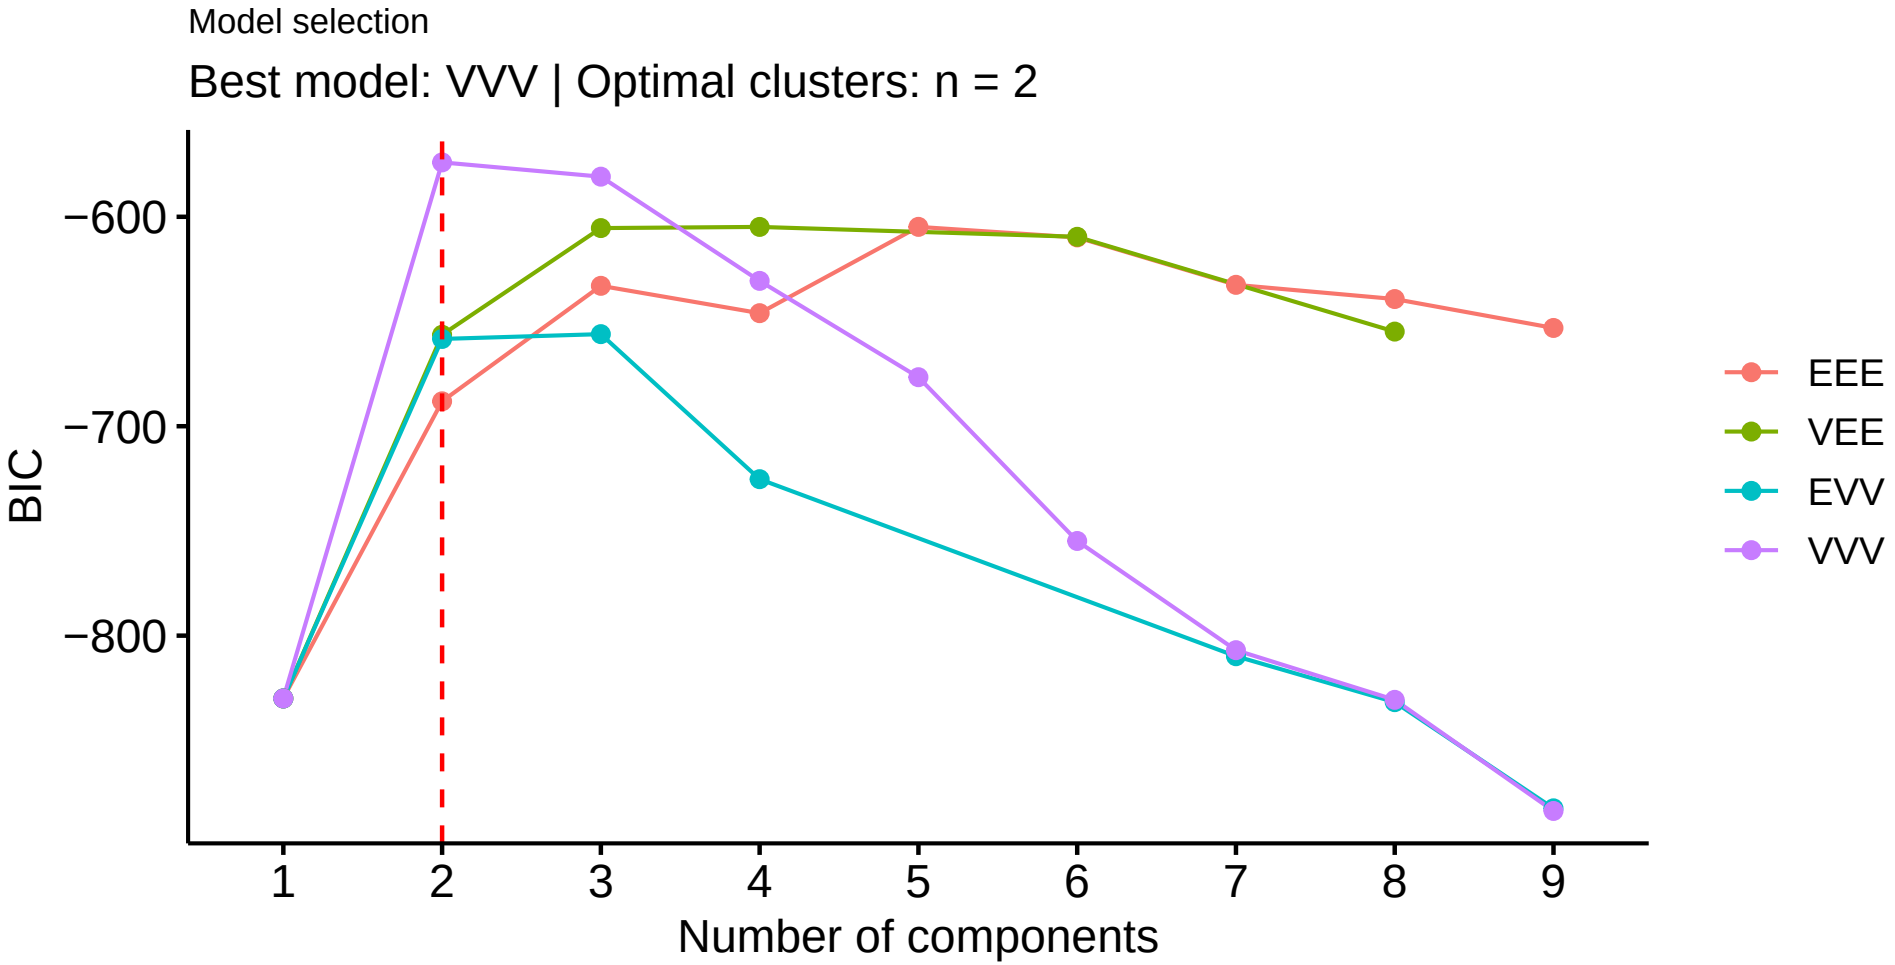
 log-likelihood   n df       BIC       ICL
      -214.3547 150 29 -574.0178 -574.0191

Clustering table:
  1   2
 50 100
```

```
# pour accéder aux paramètres
# resmclust$parameters$pro; resmclust$parameters$mean; resmclust$parameters$variance$sigma
```

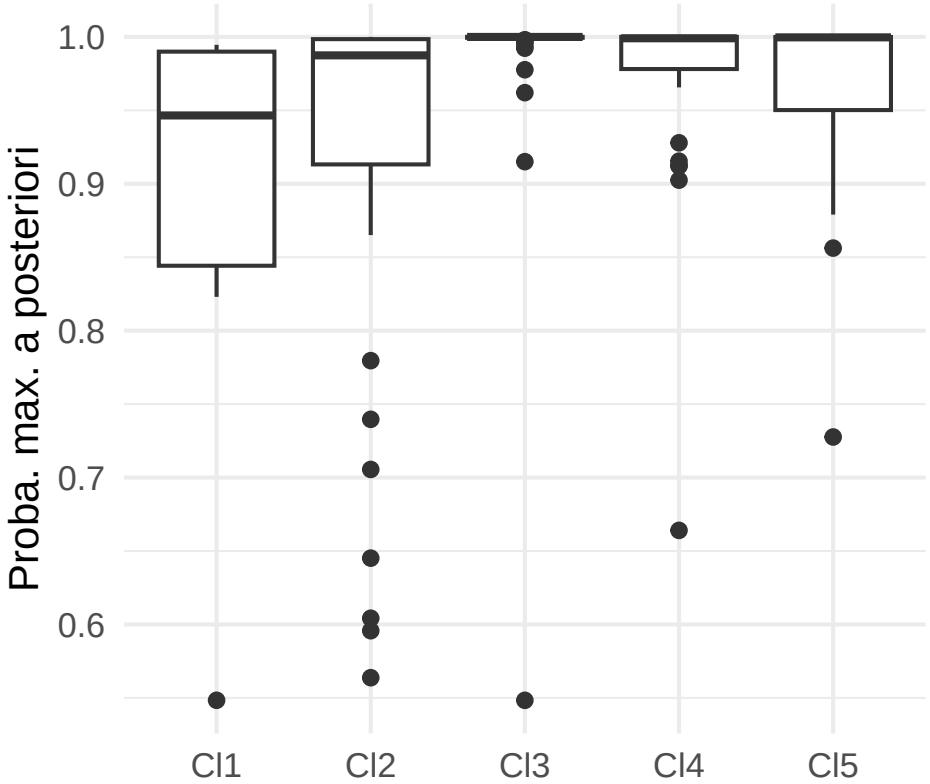
Exemple des iris avec 

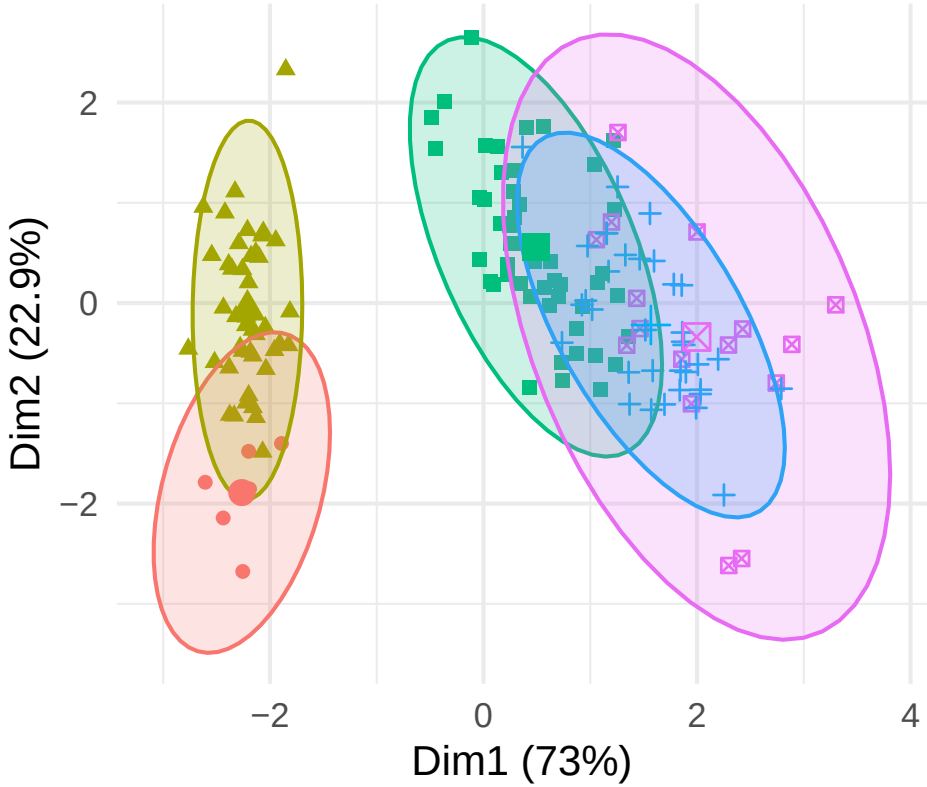
```
fviz_mclust_bic(resmclust)+theme(plot.title = element_text(size =9))+theme(legend.position = "right")
```



Exemple des iris avec 

- Classification à $K = 5$ classes
- Boxplot des probabilités conditionnelles d'appartenance





Exemple des iris avec 

- Utilisation du package `mclust`
- Sélection de modèles avec le critère ICL

```
# On peut faire la même chose avec mclustICL pour le critere ICL
modICL=mclustICL(iris[,-5],G=1:9,modelNames = c("EEE","VEE","EVV","VVV"))
summary(modICL)
```

```
Best ICL values:
             VVV,2      VVV,3      VEE,3
ICL      -574.0191 -584.05221 -612.28970
ICL diff    0.0000  -10.03311  -38.27061
```

Exemple des iris avec 

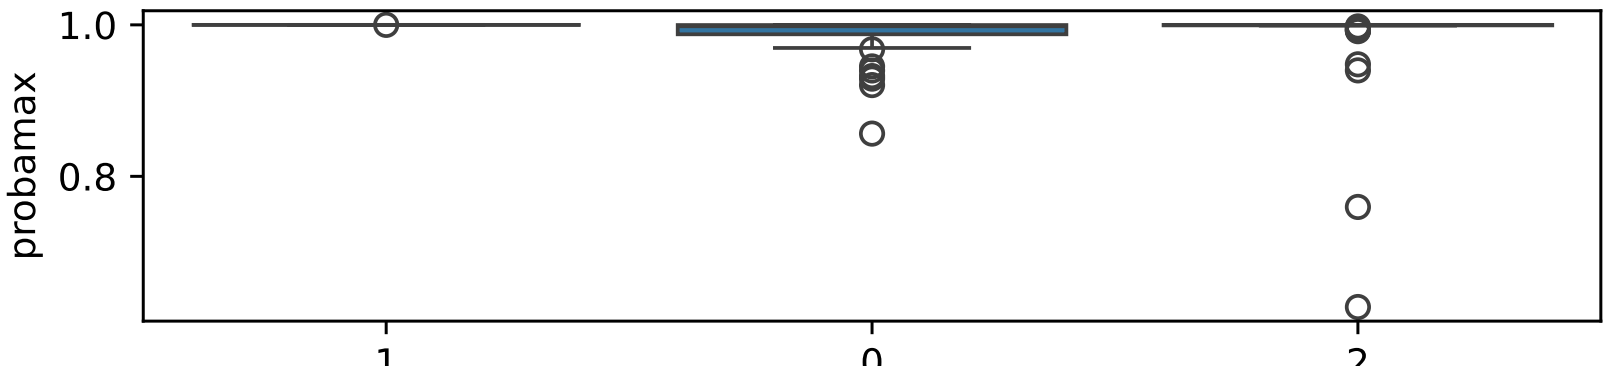
Mélange à $K = 3$ composantes

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.mixture import GaussianMixture as GMM
pyiris=r.iris
X=pyiris.iloc[:, [0, 1, 2, 3]].values

gmm=GMM(n_components=3,covariance_type="full").fit(X)

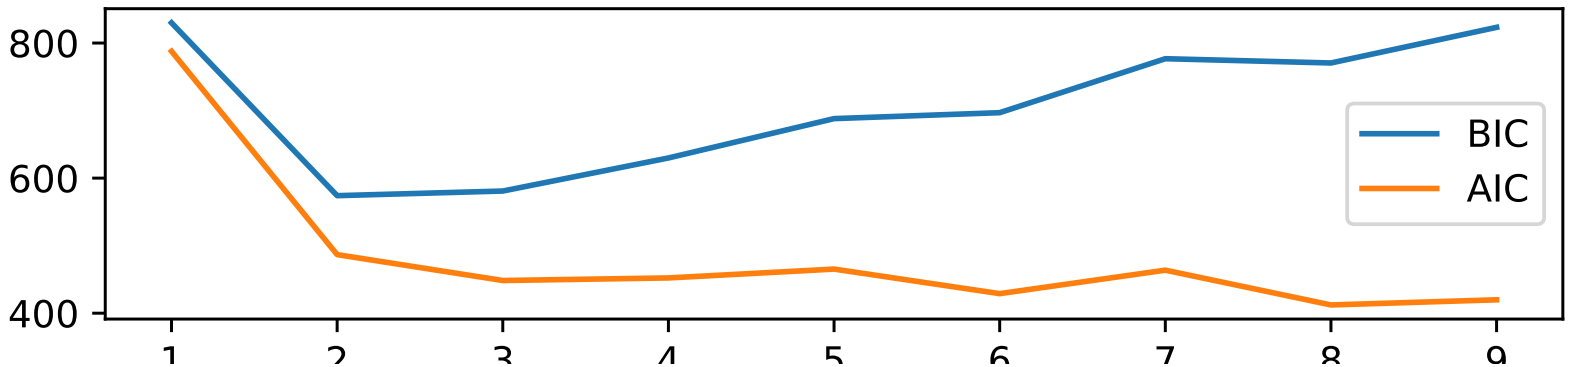
labels=gmm.predict(X)
probas=gmm.predict_proba(X)

df=pd.DataFrame({'label':list(map(str,labels)), 'probamax':np.amax(probas, axis=1)})
sns.boxplot(data=df,x='label',y='probamax')
```



Exemple des iris avec

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.mixture import GaussianMixture as GMM
X=r.iris.iloc[:, [0, 1, 2, 3]].values
n_components = np.arange(1, 10)
models = [GMM(n, covariance_type='full', random_state=0).fit(X) for n in n_components]
plt.plot(n_components, [m.bic(X) for m in models], label='BIC')
plt.plot(n_components, [m.aic(X) for m in models], label='AIC')
plt.legend(loc='best')
plt.xlabel('n_components');
```



Chapitre 4 - Classification par modèles de mélange

1. Principe
2. Étape 2 : Estimation des paramètres
3. Étape 3 : Critère de sélection de modèle
4. Les mélanges gaussiens multivariés
5. En pratique
6. References

References I

Akaike, H. 1973. "Information Theory and an Extension of the Maximum Likelihood Principle." In *Second International Symposium on Information Theory (Tsahkadsor, 1971)*, 267–81. Budapest: Akadémiai Kiadó.

Biernacki, Christophe, Gilles Celeux, and Gérard Govaert. 2000. "Assessing a Mixture Model for Clustering with the Integrated Completed Likelihood." *IEEE Transactions on Pattern Analysis and Machine Intelligence* 22 (7): 719–25.

Bouveyron, Charles, Gilles Celeux, T Brendan Murphy, and Adrian E Raftery. 2019. *Model-Based Clustering and Classification for Data Science: With Applications in r*. Vol. 50. Cambridge University Press.

Celeux, G., and J. Diebolt. 1985. "The SEM Algorithm: A Probabilistic Teacher Algorithm Derived from the EM Algorithm for the Mixture Problem." *Computational Statistics Quarterly* 2: 73–82.

Celeux, G., and G. Govaert. 1992. "A Classification EM Algorithm for Clustering and Two Stochastic Versions." *Computational Statistics and Data Analysis* 14 (3): 315–32.

References II

Delyon, B., M. Lavielle, and E. Moulines. 1999. "Convergence of a Stochastic Approximation Version of the EM Algorithm." *Annals of Statistics* 27: 94–128.

Dempster, A. P., N. M. Laird, and D. B. Rubin. 1977. "Maximum Likelihood from Incomplete Data via the EM Algorithm (with Discussion)." *Journal of the Royal Statistical Society. Series B.* 39 (1): 1–38.

Schwarz, Gideon. 1978. "Estimating the Dimension of a Model." *The Annals of Statistics* 6 (2): 461–64.

Wei, G. C. G., and M. A. Tanner. 1990. "A Monte Carlo Implementation of the EM Algorithm and the Poor Man's Data Augmentation Algorithms." *Journal of the American Statistical Association* 85: 699–704.